

TÜRKİYE CUMHURİYETİ  
YILDIZ TEKNİK ÜNİVERSİTESİ  
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ



SİBER ZORBALIK TESPİTİ

21011004 – Yavuz ÇETİN

20011502 – Osman Berkay SUKAS

BİLGİSAYAR PROJESİ

Danışman  
Prof. Dr. Banu DİRİ

Mayıs, 2024



## **TEŞEKKÜR**

---

Bize bu projede elinden geldiğince yardımcı olan, ön incelememizi daha kapsamlı yapabilmemiz için bizlere örnek makaleler veren, proje boyunca hatalarımızı düzeltmemiz için bize yol gösteren Prof. Dr. Banu Diri hocamıza teşekkürlerimizi sunarız.

Ayrıca Yıldız Teknik Üniversitesi’nde bize eğitimimiz boyunca ellerinden geldiğince yardımcı olan tüm hocalarımıza teşekkür ederiz.

Yavuz ÇETİN  
Osman Berkay SUKAS

# İÇİNDEKİLER

---

<b>KISALTMA LİSTESİ</b>	<b>vi</b>
<b>ŞEKİL LİSTESİ</b>	<b>vii</b>
<b>TABLO LİSTESİ</b>	<b>x</b>
<b>ÖZET</b>	<b>xi</b>
<b>ABSTRACT</b>	<b>xii</b>
<b>1 Giriş</b>	<b>1</b>
1.1 Siber Zorbalık Nedir? . . . . .	1
1.2 Doğal Dil İşleme . . . . .	2
<b>2 Ön İnceleme</b>	<b>4</b>
2.1 Projeye Duyulan İhtiyaç . . . . .	4
2.2 Proje Hedefleri . . . . .	4
2.3 Proje Kapsamı . . . . .	4
2.4 Proje Çıktıları . . . . .	5
<b>3 Fizibilite</b>	<b>6</b>
3.1 Teknik Fizibilite . . . . .	6
3.1.1 Yazılım Fizibilitesi . . . . .	6
3.1.2 Donanım Fizibilitesi . . . . .	6
3.2 İş Gücü ve Zaman Fizibilitesi . . . . .	7
3.3 Ekonomik Fizibilite . . . . .	7
3.4 Yasal Fizibilite . . . . .	7
<b>4 Sistem Analizi</b>	<b>8</b>
4.1 Kullanılan Veri Seti Özellikleri . . . . .	8
4.2 Kullanım Senaryosu . . . . .	8
4.2.1 Birincil Aktör . . . . .	8
4.2.2 Ön Koşullar . . . . .	8
4.2.3 Ana Akış . . . . .	9

4.2.4 Kullanım Senaryosu Diyagramı . . . . .	9
<b>5 Sistem Tasarımı</b>	<b>10</b>
5.1 Yazılım Tasarımı . . . . .	10
5.2 Kullanılan Modeller . . . . .	11
5.2.1 K En Yakın Komşular(KNN) . . . . .	11
5.2.2 Lojistik Regresyon . . . . .	11
5.2.3 Çok Terimli Naive Bayes . . . . .	12
5.2.4 Destek Vektör Makineleri . . . . .	13
5.2.5 Uzun Kısa Süreli Bellek(LSTM) . . . . .	14
5.2.6 Transformatörlerden Çift Yönlü Kodlayıcı Gösterimleri(BERT) .	15
5.2.7 RoBERTa . . . . .	16
5.2.8 ALBERT . . . . .	16
<b>6 Uygulama</b>	<b>17</b>
6.1 Veri Setinde En Sık Kullanılan Kelimeler . . . . .	17
6.2 Veri Seti ve Kategoriler . . . . .	17
6.2.1 Binary Set . . . . .	17
6.2.2 Farklı Kategorili Sınıflandırma . . . . .	18
6.3 Model Eğitimi . . . . .	18
<b>7 Deneysel Sonuçlar</b>	<b>20</b>
7.1 Kullanılan Veri Setinin Seçimi . . . . .	20
7.2 Veri Setindeki Değişiklikler . . . . .	20
<b>8 Performans Analizi</b>	<b>22</b>
8.1 Erken Çıktılar . . . . .	22
8.1.1 K En Yakın Komşular . . . . .	22
8.1.2 Lojistik Regresyon . . . . .	25
8.1.3 Çok Terimli Naive Bayes . . . . .	28
8.1.4 Destek Vektör Makineleri . . . . .	31
8.2 Son Çıktılar . . . . .	34
8.2.1 K En Yakın Komşular . . . . .	34
8.2.2 Lojistik Regresyon . . . . .	37
8.2.3 Çok Terimli Naive Bayes . . . . .	40
8.2.4 Destek Vektör Makineleri . . . . .	43
8.2.5 Uzun Kısa Süreli Bellek (LSTM) . . . . .	46
8.2.6 BERT . . . . .	50
8.2.7 RoBERTa . . . . .	52
8.2.8 ALBERT . . . . .	53

<b>9 Sonuç</b>	<b>55</b>
9.1 Makine Öğrenme Modellerinin Karşılaştırması	55
9.2 Derin Öğrenme Modellerinin Karşılaştırması	56
9.3 Önceki Araştırmalar İle Karşılaştırma	56
<b>Referanslar</b>	<b>58</b>
<b>Özgeçmiş</b>	<b>60</b>

## KISALTMA LİSTESİ

---

ALBERT	A Lite BERT
BERT	Bidirectional Encoder Representations from Transformers
CPU	Central Processing Unit
CV	Count Vectorizer
GPU	Graphics Processing Unit
KNN	K Nearest Neighbors
LSTM	Long Short-Term Memory
MLM	Masked Language Modeling
MNB	Multinomial Naive Bayes
NSP	Next Sentence Prediction
RAM	Random Access Memory
RNN	Recurrent Neural Network
RoBERTa	A Robustly Optimized BERT Pretraining Approach
SVM	Support Vector Machine
TF-IDF	Term Frequency-Inverse Document Frequency
TPU	Tensor Processing Unit

## ŞEKİL LİSTESİ

---

Şekil 3.1 Gantt Diyagramı . . . . .	7
Şekil 4.1 Kullanım Senaryosu Diyagramı . . . . .	9
Şekil 5.1 Akış Diyagramı . . . . .	10
Şekil 5.2 K En Yakın Komşular [6] . . . . .	11
Şekil 5.3 Lojistik Regresyon [7] . . . . .	12
Şekil 5.4 Naive Bayes [9] . . . . .	13
Şekil 5.5 Destek Vektör Makineleri [10] . . . . .	13
Şekil 5.6 LSTM hücresi [12] . . . . .	15
Şekil 5.7 BERT eğitim süreci [14] . . . . .	16
Şekil 6.1 En Sık Bulunan 30 Kelime . . . . .	17
Şekil 8.1 KNN CV Tüm Kategoriler Model Performansı . . . . .	22
Şekil 8.2 KNN CV Tüm Kategoriler . . . . .	23
Şekil 8.3 KNN TF-IDF Tüm Kategoriler Model Performansı . . . . .	23
Şekil 8.4 KNN TF-IDF Tüm Kategoriler . . . . .	23
Şekil 8.5 KNN CV İki Kategori Model Performansı . . . . .	24
Şekil 8.6 KNN CV İki Kategori . . . . .	24
Şekil 8.7 KNN TF-IDF İki Kategori Model Performansı . . . . .	24
Şekil 8.8 KNN TF-IDF İki Kategori . . . . .	25
Şekil 8.9 Lojistik Regresyon CV Tüm Kategoriler Model Performansı . . . . .	25
Şekil 8.10 Lojistik Regresyon CV Tüm Kategoriler . . . . .	26
Şekil 8.11 Lojistik Regresyon TF-IDF Tüm Kategoriler Model Performansı . . . . .	26
Şekil 8.12 Lojistik Regresyon TF-IDF Tüm Kategoriler . . . . .	26
Şekil 8.13 Lojistik Regresyon CV İki Kategori Model Performansı . . . . .	27
Şekil 8.14 Lojistik Regresyon CV İki Kategori . . . . .	27
Şekil 8.15 Lojistik Regresyon TF-IDF İki Kategori Model Performansı . . . . .	27
Şekil 8.16 Lojistik Regresyon TF-IDF İki Kategori . . . . .	28
Şekil 8.17 MNB CV Tüm Kategoriler Model Performansı . . . . .	28
Şekil 8.18 MNB CV Tüm Kategoriler . . . . .	29
Şekil 8.19 MNB TF-IDF Tüm Kategoriler Model Performansı . . . . .	29
Şekil 8.20 MNB TF-IDF Tüm Kategoriler . . . . .	29
Şekil 8.21 MNB CV İki Kategori Model Performansı . . . . .	30

Şekil 8.22 MNB CV İki Kategori . . . . .	30
Şekil 8.23 MNB TF-IDF İki Kategori Model Performansı . . . . .	30
Şekil 8.24 MNB TF-IDF İki Kategori . . . . .	31
Şekil 8.25 SVM CV Tüm Kategoriler Model Performansı . . . . .	31
Şekil 8.26 SVM CV Tüm Kategoriler . . . . .	32
Şekil 8.27 SVM TF-IDF Tüm Kategoriler Model Performansı . . . . .	32
Şekil 8.28 SVM TF-IDF Tüm Kategoriler . . . . .	32
Şekil 8.29 SVM CV İki Kategori Model Performansı . . . . .	33
Şekil 8.30 SVM CV İki Kategori . . . . .	33
Şekil 8.31 SVM TF-IDF İki Kategori Model Performansı . . . . .	33
Şekil 8.32 SVM TF-IDF İki Kategori . . . . .	34
Şekil 8.33 KNN CV Tüm Kategoriler Model Performansı . . . . .	34
Şekil 8.34 KNN CV Tüm Kategoriler . . . . .	35
Şekil 8.35 KNN TF-IDF Tüm Kategoriler Model Performansı . . . . .	35
Şekil 8.36 KNN TF-IDF Tüm Kategoriler . . . . .	35
Şekil 8.37 KNN CV İki Kategori Model Performansı . . . . .	36
Şekil 8.38 KNN CV İki Kategori . . . . .	36
Şekil 8.39 KNN TF-IDF İki Kategori Model Performansı . . . . .	36
Şekil 8.40 KNN TF-IDF İki Kategori . . . . .	37
Şekil 8.41 Lojistik Regresyon CV Tüm Kategoriler Model Performansı . . . . .	37
Şekil 8.42 Lojistik Regresyon CV Tüm Kategoriler . . . . .	38
Şekil 8.43 Lojistik Regresyon TF-IDF Tüm Kategoriler Model Performansı . . . . .	38
Şekil 8.44 Lojistik Regresyon TF-IDF Tüm Kategoriler . . . . .	38
Şekil 8.45 Lojistik Regresyon CV İki Kategori Model Performansı . . . . .	39
Şekil 8.46 Lojistik Regresyon CV İki Kategori . . . . .	39
Şekil 8.47 Lojistik Regresyon TF-IDF İki Kategori Model Performansı . . . . .	39
Şekil 8.48 Lojistik Regresyon TF-IDF İki Kategori . . . . .	40
Şekil 8.49 MNB CV Tüm Kategoriler Model Performansı . . . . .	40
Şekil 8.50 MNB CV Tüm Kategoriler . . . . .	41
Şekil 8.51 MNB TF-IDF Tüm Kategoriler Model Performansı . . . . .	41
Şekil 8.52 MNB TF-IDF Tüm Kategoriler . . . . .	41
Şekil 8.53 MNB CV İki Kategori Model Performansı . . . . .	42
Şekil 8.54 MNB CV İki Kategori . . . . .	42
Şekil 8.55 MNB TF-IDF İki Kategori Model Performansı . . . . .	42
Şekil 8.56 MNB TF-IDF İki Kategori . . . . .	43
Şekil 8.57 SVM CV Tüm Kategoriler Model Performansı . . . . .	43
Şekil 8.58 SVM CV Tüm Kategoriler . . . . .	44
Şekil 8.59 SVM TF-IDF Tüm Kategoriler Model Performansı . . . . .	44
Şekil 8.60 SVM TF-IDF Tüm Kategoriler . . . . .	44

Şekil 8.61 SVM CV İki Kategori Model Performansı . . . . .	45
Şekil 8.62 SVM CV İki Kategori . . . . .	45
Şekil 8.63 SVM TF-IDF İki Kategori Model Performansı . . . . .	45
Şekil 8.64 SVM TF-IDF İki Kategori . . . . .	46
Şekil 8.65 LSTM BERT vektörleştirme Tüm Kategoriler Model Performansı .	46
Şekil 8.66 LSTM BERT Tüm Kategoriler . . . . .	47
Şekil 8.67 LSTM FastText Tüm Kategoriler Model Performansı . . . . .	47
Şekil 8.68 LSTM FastText Tüm Kategoriler . . . . .	47
Şekil 8.69 LSTM Word2Vec vektörleştirme Tüm Kategoriler Model Performansı	48
Şekil 8.70 LSTM Word2Vec Tüm Kategoriler . . . . .	48
Şekil 8.71 LSTM BERT vektörleştirme İki Kategori Model Performansı . . . . .	48
Şekil 8.72 LSTM BERT İki Kategori . . . . .	49
Şekil 8.73 LSTM FastText İki Kategori Model Performansı . . . . .	49
Şekil 8.74 LSTM FastText İki Kategori . . . . .	49
Şekil 8.75 LSTM Word2Vec İki Kategori Model Performansı . . . . .	50
Şekil 8.76 LSTM Word2Vec İki Kategori . . . . .	50
Şekil 8.77 BERT Tüm Kategoriler Model Performansı . . . . .	50
Şekil 8.78 BERT Tüm Kategoriler . . . . .	51
Şekil 8.79 BERT İki Kategori Model Performansı . . . . .	51
Şekil 8.80 BERT İki Kategori . . . . .	51
Şekil 8.81 RoBERTa Tüm Kategoriler Model Performansı . . . . .	52
Şekil 8.82 RoBERTa Tüm Kategoriler . . . . .	52
Şekil 8.83 RoBERTa İki Kategori Model Performansı . . . . .	52
Şekil 8.84 RoBERTa İki Kategori . . . . .	53
Şekil 8.85 ALBERT Tüm Kategoriler Model Performansı . . . . .	53
Şekil 8.86 ALBERT Tüm Kategoriler . . . . .	54
Şekil 8.87 ALBERT İki Kategori Model Performansı . . . . .	54
Şekil 8.88 ALBERT İki Kategori . . . . .	54

## TABLO LİSTESİ

---

Tablo 3.1 Maliyetler . . . . .	7
Tablo 4.1 Siber Zorbalık Türleri . . . . .	8
Tablo 7.1 Veri Setlerindeki Doğruluk Oranları . . . . .	20
Tablo 7.2 Veri Setlerindeki Doğruluk Oranları . . . . .	21
Tablo 9.1 Makine Öğrenme Modellerinin Doğruluk Oranları Karşılaştırması	55
Tablo 9.2 Derin Öğrenme Modellerinin Doğruluk Oranları Karşılaştırması	56
Tablo 9.3 Karşılaştırma Tablosu . . . . .	56

## ÖZET

---

# SİBER ZORBALIK TESPİTİ

Yavuz ÇETİN  
Osman Berkay SUKAS

Bilgisayar Mühendisliği Bölümü  
Bilgisayar Projesi

Danışman: Prof. Dr. Banu DİRİ

Son yıllarda çıkan birçok yeni yapay zeka modeliyle beraber doğal dil işlemenin insan hayatındaki önemi hızlıca artmaktadır. Doğal dil işleme araştırmalarının hız kazanmasıyla beraber siber zorbalık konusu araştırmacıların ilgisini çekmektedir. Siber zorbalığın çevrimiçi insan hayatını son derece olumsuz etkilediği, insanları intihara ve kendine zarar gibi kötü yollara sürüklendiği bilinmektedir.

Bu çalışmamız sayesinde sosyal medyada insanların daha güvenli bir şekilde zaman geçirebilmeleri için siber zorbalık olarak ifade edilebilecek cümlelerin tespiti amaçlanmaktadır. Proje kapsamında birçok makine öğrenmesi ve derin öğrenme yöntemiyle siber zorbalık içerikli cümlelerin olabildiğince yüksek başarıyla tespiti amaçlanmaktadır.

**Anahtar Kelimeler:** Makine Öğrenmesi, Derin Öğrenme, Siber Zorbalık, Ön İşleme, Naive Bayes, Destek Vektör Makineleri (SVM), K En Yakın Komşular (KNN), Uzun Kısa Süreli Bellek (LSTM), Transformatörlerden Çift Yönlü Kodlayıcı Gösterimleri (BERT)

## **ABSTRACT**

---

# **CYBERBULLYING DETECTION**

Yavuz ÇETİN  
Osman Berkay SUKAS

Department of Computer Engineering  
Computer Project

Advisor: Prof. Dr. Banu DİRİ

With many new artificial intelligence models emerging in recent years, the importance of natural language processing in human life is rapidly increasing. With the acceleration of natural language processing research, the issue of cyberbullying has attracted the attention of researchers. It is known that cyberbullying has an extremely negative impact on people's lives online and can lead people to suicide and self-harm.

This study aims to detect sentences that can be expressed as cyberbullying so that people can spend time more safely on social media. Within the scope of the project, it is aimed to detect cyberbullying sentences with as high success as possible with many machine learning and deep learning methods.

**Keywords:** Machine Learning, Deep Learning, Cyberbullying, Preprocessing, Naive Bayes, Support Vector Machines (SVM), K-Nearest Neighbors (KNN), Long-Short Term Memory (LSTM), Bidirectional Encoder Representations from Transformers (BERT)

# 1 Giriş

---

Bu bölümde, siber zorbalık ve doğal dil işleme tekniklerinden bahsedilecektir.

## 1.1 Siber Zorbalık Nedir?

Gelişen teknoloji ile insanların internet kullanım miktarlarında önemli bir artış gerçekleşmiştir. Son yıllarda yaşanan pandemi ve deprem gibi çeşitli felaketler sebebiyle insanların sosyal medya kullanımını tüm zamanların en yüksek seviyesine çıkarmıştır. Bu artışlar beraberinde çeşitli olumsuz sonuçları da getirmiştir. Bunlardan biri de son yıllarda artan siber zorbalık faaliyetleri olarak verilebilir.

Siber zorbalık, kötü niyetli kişiler tarafından diğer kullanıcılarla yönelik zararlı ve hoş olmayan davranışları içeren internet ortamında yapılan bir zorbalık biçimidir. Siber zorbalığa örnek olarak birine hakaret içerikli mesajlar göndermek, taciz edici yorumlar veya resimler göndermek, birinin kişisel bilgilerini izin almadan kullanmak ve başkalarına rahatsızlık vermek için sahte hesaplar oluşturmak söylenebilir. Ayrıca, herhangi birinin utanç verici fotoğraflarını yaynlamak veya kurbanı kötü göstermek amacıyla çevrimiçi içeriği manipüle etmek de siber zorbalık kapsamında değerlendirilebilir [1].

Siber zorbalık, sosyal medyada 8 farklı yolla yapılmaktadır [2].

- **Aşağılama:** Kişinin itibarını zedelemek için asılsız söylentiler yayararak kişiyi küçük düşürmek.
- **Dışlama:** Bilinçli olarak birini çevrimiçi grupların dışında tutmak.
- **Kıskırtma:** Kaba ve saldırgan mesajlarla insanları tartışmalara teşvik etmek.
- **Hile:** Kişiyi kandırarak kişisel bilgilerini veya fotoğraflarını elde edip sosyal medyada bunları paylaşmak.

- **Taciz:** Sürekli saldırgan mesajlar gönderme veya çevirmiçi olarak bu mesajları paylaşmak.
- **Kimlik Hırsızlığı:** Sahte profiller oluşturma veya hesapları ele geçirme yoluyla kişinin itibarını zedeleyici içerikler paylaşmak.
- **Gezinti:** Bir kişinin fotoğraflarını veya kişisel bilgilerini kendisiin haberini olmadan onu utandırmak için paylaşmak.
- **Siber Konuşma:** Tehdit içerikli mesaj göndermek.

Birçok sosyal medya sitesinde siber zorbalık önlemek için adım atmasına rağmen bu çabalar yeterli sonuç vermediği görülmektedir. Kötü niyetli kişiler, siber zorbalık önlemlerinden kaçınmak için çeşitli yöntemler kullanabilmektedir. Bu yöntemlere örnek vermek gerekirse, hakaret içerikli mesajlardaki bir veya birden fazla harfi değiştirme veya kişilerin yakınlarının kimliğine bürünme yaygın olarak kullanılan taktiklerdir.

Siber zorbalığa meruz kalan bireylerde; genellikle toplumdan soyutlanma, itibar kaybı, aile ve iş hayatlarının bozulması, depresyon ve bunun sonucunda intihar düşüncüleri gibi durumlar görülebilmektedir [3].

## 1.2 Doğal Dil İşleme

Doğal Dil İşleme, makinelerin insan dillerini anlamasını ve işlemesini sağlayan bir yapay zeka alanıdır. [4]. Doğal Dil İşleme uygulamaları için, metinlerin bilgisayarlar tarafından işlenebilir bir formata dönüştürülmesi gerekmektedir. Bu dönüşüm, metinlerin semantik anımlarını koruyarak bilgisayarlar tarafından bu metinlerin anlaşılabilmesini sağlamaktadır. Bu sürecin temel aşamaları şunlardır:

- **Gereksiz ifadelerin temizlenmesi:** Metin verisinden sayılar, hashtagler, emojiler, emotikonlar, noktalama işaretleri, kullanıcı adları, linkler temizlenir.
- **Kelimelere ayrıştırma:** Metinler, önce cümlelere, ardından kelimelelere ayrılır. Bu işlem genellikle boşluk karakteri veya diğer ayraçlar kullanılarak yapılır.
- **Kök bulma:** Kelimelerin morfolojik analizini yaparak çekim eklerini kaldırır, örnek verecek olursak "sözcük" ve "sözcükler" kelimeleri aynı kök kelime olan "sözcük"e dönüştürülür. Bu işlemde, kelimelerin anlamlı kök parçaları elde edilir.

- **Durak kelimelerin temizlenmesi:** Genellikle cümle anlamına büyük katkı sağlamayan, ancak sıkça kullanılan kelimelerdir. Bu kelimeler, çıkarılmadığı takdirde anlamlandırma sürecini olumsuz etkileyebilecek gürültüye neden olabilir.
- **Kelime temsilleri:** Bilgisayarların metinleri matematiksel olarak işleyebilmesi için sözlü ifadelerin matematiksel temsilleri oluşturulur. Bu süreçte, çeşitli teknikler kullanılarak kelime temsilleri elde edilir.
  - **Countvectorizer:** Metin belgeleri alınır ve her bir belgedeki kelimelerin sayısını içeren vektörler oluşturulur. Bu vektörler, bir makine öğrenimi modeline girdi olarak verilebilir.
  - **TF-IDF:** Bir terimin bir belgedeki sıklığı ile tüm belgelerdeki görülme sıklığını birleştirerek, o terimin belgedeki önemini belirler. TF-IDF, bir belgedeki önemli terimleri belirlemek ve belgeleri birbirinden ayırmak için etkili bir araçtır.

## 2 Ön İnceleme

---

Bu bölümde projeden beklenenler ve projenin kapsamı anlatılacaktır.

### 2.1 Projeye Duyulan İhtiyaç

Siber zorbalık, çevrimiçi platformlarda yaygınlaşan ve bireylere zarar vermek amacıyla gerçekleştirilen kötü niyetli davranışlardır. Bireyleri korumak, toplumu bilinçlendirmek, suçun önlenmesine yardımcı olmak, hukuki süreçlerde delil sağlamak ve çevrimiçi ortamların güvenliğini artırmak için siber zorbalık tespiti yapabilen bir projeye ihtiyaç duyulmaktadır.

### 2.2 Proje Hedefleri

İngilizce twitter mesajları üzerinde doğal dil işleme teknikleri, makine öğrenmesi ve derin öğrenme yöntemleri kullanılacaktır. Bu işlemler sonunda twitter mesajlarında siber zorbalık olup olmadığıının bulunması ve buna göre sınıflandırma yapılması hedeflenmektedir.

### 2.3 Proje Kapsamı

Projede, ingilizce twitter mesajları içeren bir veri seti üzerinde ön işleme teknikleri uygulanarak veri seti istenilen hale çevrilecektir. Veri seti daha sonrasında training ve test olmak üzere iki parçaya bölünecektir. Traning veri seti üzerinde çeşitli makine öğrenmesi ve derin öğrenme yöntemleri kullanılacaktır. Proje sonucunda kullanılan modellerin performansı karşılaştırılacaktır ve siber zorbalık tespitinde hangi modelin diğerlerine göre daha etkili olabileceği bulunmaya çalışılacaktır.

## **2.4 Proje Çıktıları**

Projede, kullanılan farklı modellerin ingilizce metinler üzerinde elde ettiği hassasiyet ve doğruluk oranları çıkarılmaktadır.

# 3

## Fizibilite

---

Bu bölümde projenin teknik, zaman, ekonomik ve yasal fizibilitesi hakkında bilgi verilmektedir.

### 3.1 Teknik Fizibilite

Teknik Fizibilite, Yazılım Fizibilitesi ve Donanım Fizibilitesi olarak iki başlık altında ele alınmıştır.

#### 3.1.1 Yazılım Fizibilitesi

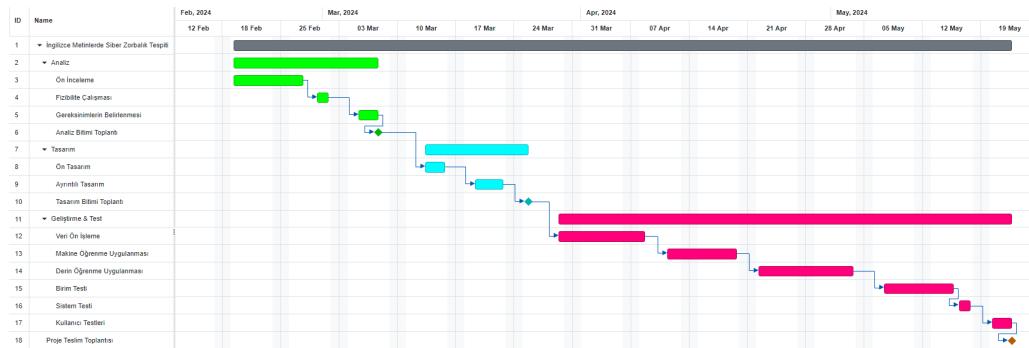
İşletim sistemi olarak Windows 10 seçilmiştir. Programın geliştirileceği dil olarak Python kullanılmıştır. Python, makine öğrenmesi ve derin öğrenmeye yardımcı olacak birçok kütüphaneyi barındırması yüzünden tercih edilmiştir. Ayrıca Jupyter Notebook'da adım adım işlemleri daha rahat kontrol edebildiğimiz için projemizde kullanma gereği duyulmuştur.

#### 3.1.2 Donanım Fizibilitesi

Veri setinin ön işlemesi için yüksek bir işlem gücüne ihtiyaç duyulmamıştır. Aynı zamanda makine öğrenmeleri ile modeli eğitmek orta derecede bir işlem gücüyle yapılmıştır. Ancak derin öğrenme için gerekli donanım daha üst seviyede olduğu için Google Colab hizmeti kullanılmıştır. Bu hizmet bize daha yüksek hacimli işlemleri yapabilmemiz için gerekli GPU, CPU, TPU, RAM desteği sağlamıştır. Elbette diğer işlem adımlarını daha hızlı yapabilmek için gerekli görüldüğü zaman bu hizmetten yararlanılmıştır.

## 3.2 İş Gücü ve Zaman Fizibilitesi

Bu proje için 2 kişi 3 ay süre harcamıştır. Zaman Fizibilitesinin daha ayrıntılı hâli Şekil 3.1'de Gantt diyagramı kullanılarak ifade edilmiştir.



Şekil 3.1 Gantt Diyagramı

## 3.3 Ekonomik Fizibilite

Projenin geliştirildiği ortam olan Google Colab ve Jupyter Notebook'un ücretsiz sürümlerinden faydalananlığı için geliştirme ortamına herhangi bir ücret ödenmemiştir. Makine öğrenmesi ve derin öğrenme için de kullanılan Python kütüphanelerine ücretsiz bir şekilde erişim sağlanıldığı için makine öğrenmesi ve derin öğrenmeye de bir ücret ödenmemiştir. Projedeki veri seti, Kaggle'den ücretsiz bir şekilde temin edilmiştir. Kişisel bilgisiyarlarımızın donanımı projeyi çalıştırabilmek için yeterli durumdadır.

Detaylı maliyet tablosu Tablo 3.1'de ayrıntılı bir şekilde verilmiştir.

Tablo 3.1 Maliyetler

Gider Kalemleri	Ücret
HP Omen 17-AN106NT	11099 TL
Excalibur E600	24609 TL
Google Colab	Ücretsiz
Jupyter Notebook	Ücretsiz
Python Kütüphaneleri	Ücretsiz
Veri Seti	Ücretsiz
Toplam	35708 TL

## 3.4 Yasal Fizibilite

Projemizde kullanılan veri seti Kaggle [5] üzerinden alınmıştır. Açık kaynaklı veri seti olduğu için herhangi bir yasal sorun teşkil etmemiştir. Kullanılan Python ve kütüphaneleri açık kaynaklıdır. Bundan dolayı herhangi bir patent veya telif hakkı ihlali bulunmamıştır.

# 4

## Sistem Analizi

---

Bu bölümde projede kullanılacak veri setinden, projenin kullanım senaryosundan bahsedilecektir.

### 4.1 Kullanılan Veri Seti Özellikleri

Kullanılan veri seti 47.692 adet ingilizce twitter mesajından oluşmaktadır. Veri setinde bulunan siber zorbalık türleri Tablo 4.1'da gösterilmiştir.

**Tablo 4.1** Siber Zorbalık Türleri

Siber Zorbalık Türü	Sayısı
Din	7998
Yaş	7992
Cinsiyet	7973
Irk	7961
Siber Zorbalık Değil	7945
Diğer Siber Zorbalıklar	7823

### 4.2 Kullanım Senaryosu

Bu bölümde projenin basit bir şekilde kullanım senaryosu anlatılacaktır.

#### 4.2.1 Birincil Aktör

Kullanıcı: Verdiği metnin siber zorbalık olup olmadığını öğrenmek.

#### 4.2.2 Ön Koşullar

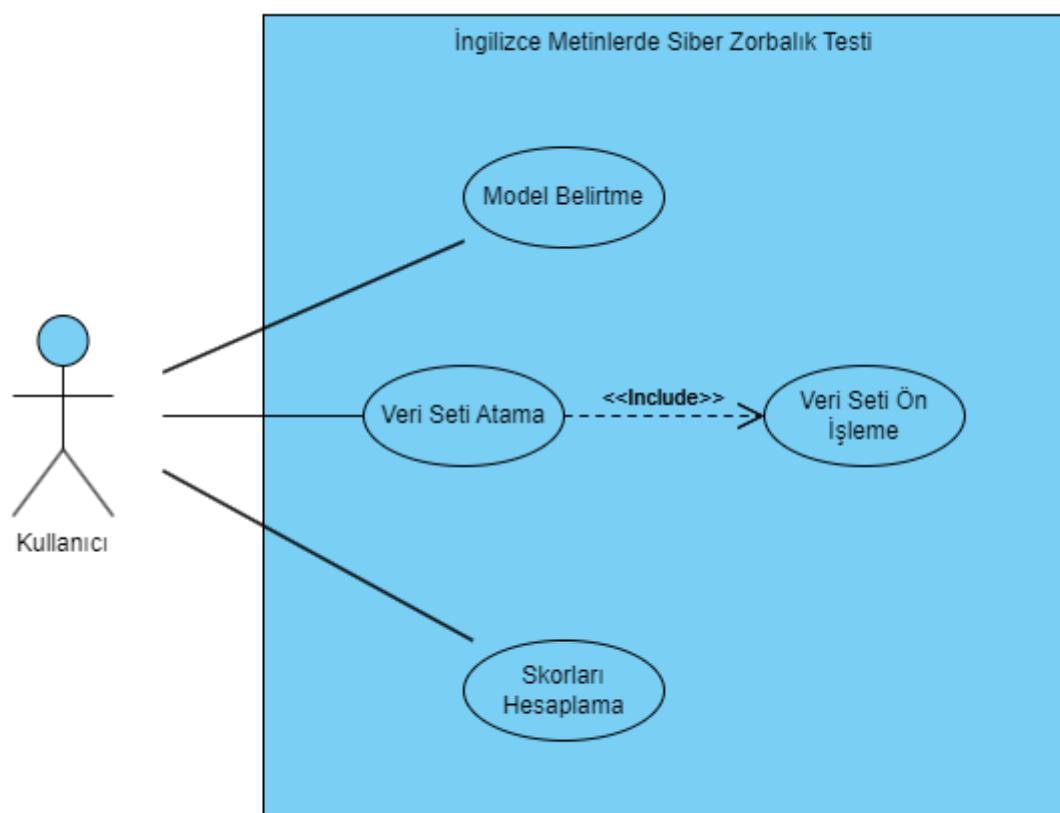
Veri setinin işlenmiş olması. Kullanılacak modelin seçilmiş olunması.

#### 4.2.3 Ana Akış

1. Veri setinin okunması.
2. Veri setinin eğitim ve test olarak bölünmesi.
3. Veri setinin seçilen modele verilmesi.
4. Çıkan sonuçların incelenmesi.

#### 4.2.4 Kullanım Senaryosu Diyagramı

Sistemin kullanım senaryosu diyagramı Şekil 4.1'de ifade edilmiştir.



Şekil 4.1 Kullanım Senaryosu Diyagramı

# 5 Sistem Tasarımı

---

Bu bölümde projenin akışı diyagramı ve kullanılan makine öğrenmesi ve derin öğrenme yöntemlerinden bahsedilecektir.

## 5.1 Yazılım Tasarımı

Sistemin çalışmasının akış diyagramı Şekil 5.1'de ifade edilmiştir.



Şekil 5.1 Akış Diyagramı

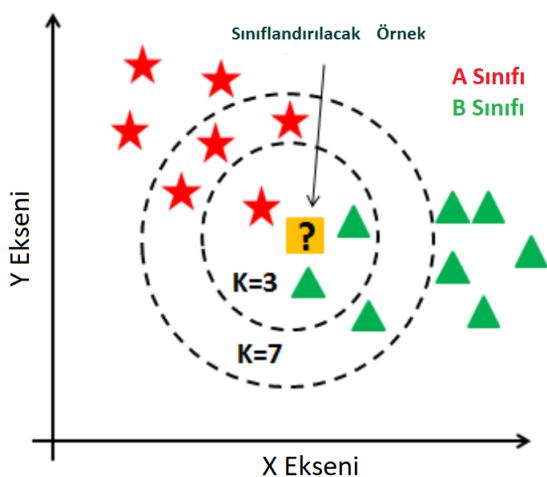
## 5.2 Kullanılan Modeller

Proje kapsamında 4 adet makine öğrenmesi yöntemi ve 4 adet derin öğrenme modeli kullanılmıştır. Kullanılan modeller ve çalışma prensiblerinden bu bölümde bahsedilecektir.

### 5.2.1 K En Yakın Komşular(KNN)

Bu sınıflandırma algoritması çeşitli yapay zeka projelerinde sıkça kullanılan algoritmaların birisidir. Sıkça tercih edilme sebebi olarak eğitim gerekmemesi ve çok hızlı çalışması verilebilir. Sınıflandırmak için veri içerisindeki benzerlik oranlarını kullanır. Bir noktada bulunan verinin etrafındaki verilerin nasıl sınıflandırıldığına bakarak sınıflandırılması işlemi olarak da açıklanabilir. Bu işlem bir seçim sürecine benzetilebilir. Verilen  $K$  adet en yakın tüm noktalar kendi sınıfına 1 oy eklemektedir. Böylece sınıflandırılması istenilen sınıf en çok oyu alan sınıfına sınıflandırılmış olmaktadır. Kullanılan verilerin komşuluk mesafesini bulmak için genellikle Öklid Bağıntısı kullanılır. Bu yapay zeka algoritması yöntem, eğitim gerektirmediği için ve gürültüye karşı avantajları nedeniyle siber zorbalık projelerine uygundur [3].

KNN algoritmasının çalışması Şekil 5.2'de ifade edilmiştir.



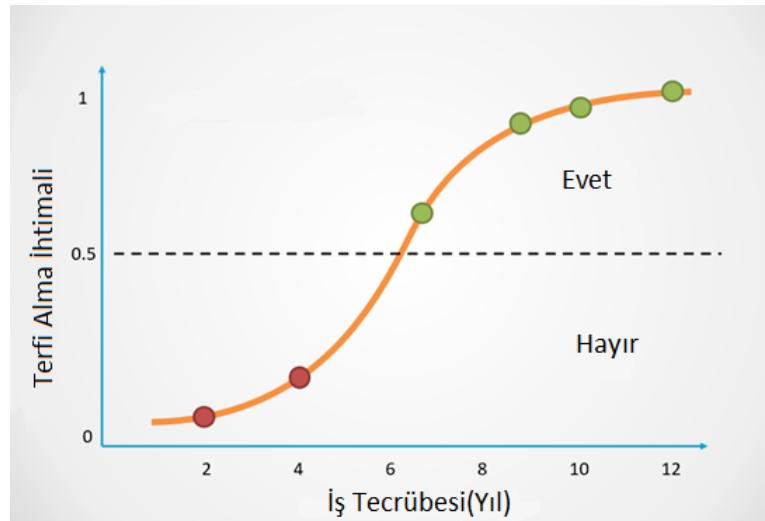
**Şekil 5.2** K En Yakın Komsular [6]

### 5.2.2 Lojistik Regresyon

Bu sınıflandırma algoritması farklı değişkenler verildiğinde binary bir sonuç tahmin etmek için kullanılmaktadır. Lojistik regresyon, bir işin veya olayın gerçekleşme ihtimalini gerçekleştirebilir veya gerçekleşmez olarak ikiye ayırrı. Lojistik regresyonda kullanılan eşitlik için lineer regresyona sigmoid fonksiyonu koyulmasıyla elde edilmektedir. Siber zorbalık tespitinde ve birden fazla sınıf içeren sınıflandırma

projelerinde, sınıfların ayrimı ve aralarında ilişki kurulması için sıkça kullanılmaktadır [3].

Lojistik regresyon algoritmasının çalışma prensibi Şekil 5.3'de ifade edilmiştir.

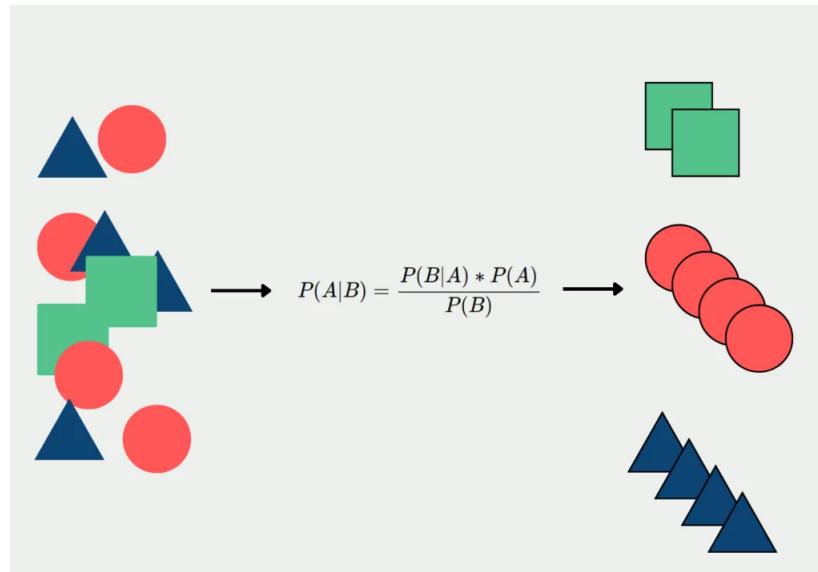


Şekil 5.3 Lojistik Regresyon [7]

### 5.2.3 Çok Terimli Naive Bayes

Bu sınıflandırma algoritması, veri seti içerisindeki sınıfların girdilerinin birbirine bağlı olmadıklarını kabul eder ve özelliklerin sınıflandırmaya etkisini belirlemek için Bayes Teoremi'nden faydalananır. Her bir sınıf için özelliklerin olasılıkları hesaplanır ve bu olasılıklardan faydalanaarak en olası sınıf seçilir. Sınıfları birbirinden bağımsız saydığı için bu algoritma genellikle hızlı çalışmaktadır. Fakat eğer veri setindeki girdilerin beklenen sonuçları birbirleriyle bağlantılıysa bu varsayımlı modelin performansının düşük olmasına sebep olabilir. Bu nedenle bazı durumlarda istenilen sonuç alınamayabilir. Bu sınıflandırma algoritması çalışma prensibinin basit olması ve genellikle diğer algoritmalarдан daha iyi sonuçlar vermesi sebebiyle siber zorbalık projelerinde sıkça kullanılmaktadır. [8].

Naive Bayes algoritmasının temelini oluşturan teorem Şekil 5.4'de ifade edilmiştir.

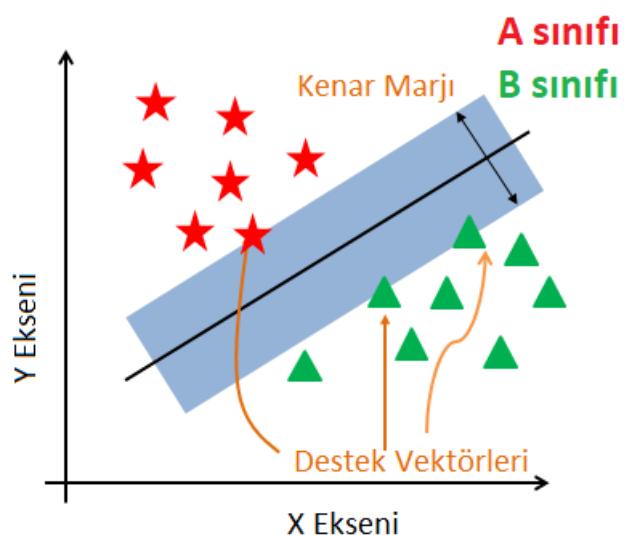


**Şekil 5.4** Naive Bayes [9]

#### 5.2.4 Destek Vektör Makineleri

Bu algoritma sınıflandırma işlemlerinde en sık kullanılan algoritmaların biridir. Veri noktalarını sınıflandırmak için en iyi ayırt edici hiperdüzlemi bulmaya çalışır. Bu hiperdüzlemi bulurken iki sınıf arasındaki mesafenin(kenar marjı) olabildiğince büyük olması hedeflenir. Bu algoritma, büyük veri setlerinde çok hızlı çalışması, verileri doğrusal ve doğrusal olmayan şekilde ayırmaları ve bu ayırmaların içerisinde en iyisini seçebilme yeteneği ile siber zorbalık araştırmalarında sıkça tercih edilir [8].

Destek vektör makinelerinin çalışma mantığı Şekil 5.5'de ifade edilmiştir.



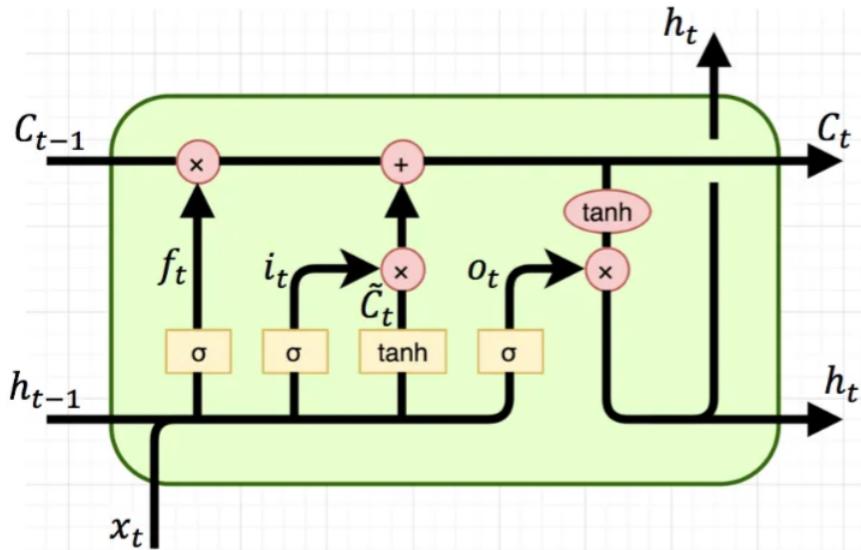
**Şekil 5.5** Destek Vektör Makineleri [10]

### 5.2.5 Uzun Kısa Süreli Bellek(LSTM)

Derin öğrenme alanında kullanılan bir tür Rekürrent Sinir Ağları(RNN) mimarisidir. Standard RNN'lerde sadece bir adet hidden state bilgisi işlem boyunca kullanılır. Fakat bu sistemin uzun süreli bilgiler ile bağlantı kurup daha sağlıklı sonuçlar vermesini engellemektedir. LSTM sistemleri bunun önüne geçmek için memory cell(Hafıza hücresi) denilen bir yapı kullanır. Bu yapı bilgileri uzun süre tutma yeteneğine sahiptir. Bu yapıyı 3 adet kapı kontrol eder. Bu kapılar Giriş kapısı, Unutma kapısı, Çıkış kapısıdır.

- Giriş Kapısı - Hafıza hücresinin durumunu güncelleyen bir kapıdır. Önceki ve o anki bilginin sigmoid fonksiyonuna verilmemesi sonucunda hafıza hücresinin güncellenip güncellenmeyeceği kararı verilir. Eğer bilgi 0 ise önemsiz, 1 ise önemli olarak kabul edilmektedir. Burada tanh fonksiyonundan elde edilen çıktılar sigmoid fonksiyonu çıktılarıyla çarpılarak hangi bilgilerin güncelleneceği kararı verilir [11].
- Unutma Kapısı - Burada hangi bilgilerin unutulacağına veya saklanacağı kararı verilmektedir. Önceki bilgi ile o anki bilgi sigmoid fonksiyonuna sokulduktan sonra karar verilmektedir. 0 olan bilgiler unutulur ve 1 olan bilgiler hafıza hücresinde durmaya devam eder.
- Çıkış Kapısı - Bu kapı bir sonraki hücrenin giriş bilgisini belirler. İlk olarak eski bilgi ve o anki bilgi sigmoid fonksiyonuna verilir. Daha sonrasında ise hafıza hücresinde bulunan bilgi tanh fonksiyonundan geçer. Elde edilen 2 sonuç çarpılır ve böylece karar verilir. Bu işlemler sonucunda hidden state bilgilerine karar verilir.

Basit bir LSTM hücresi örneği Şekil 5.6'da ifade edilmiştir.



Şekil 5.6 LSTM hücresi [12]

### 5.2.6 Transformatörlerden Çift Yönlü Kodlayıcı Gösterimleri(BERT)

BERT, doğal dil işleme görevlerinin verimliliğini artırmak amacıyla geliştirilmiş bir derin öğrenme dil modelidir [13]. BERT, metindeki belirsiz dilin anlamını çevresindeki metni kullanarak anlamaya yardımcı olmaktadır. Vikipedi metinleriyle önceden eğitilmiş olup soru cevap veri setleriyle ince ayarlar yapılmaktadır.

BERT'in temeli, her çıktı elemanın her girdi elemanıyla bağlı olduğu ve ağırlıklarının dinamik olarak hesaplandığı derin öğrenme modeli olan transformatörlerdir. BERT, metinleri her iki yönü (soldan sağa ve sağdan sola) aynı anda okuyabilen çift yönlü bir yapıya sahiptir. Bu özellik, transformatör modellerinin tanıtılmıştır mümkün kılınmıştır.

BERT modelinin iki tane eğitim süreci vardır [14]:

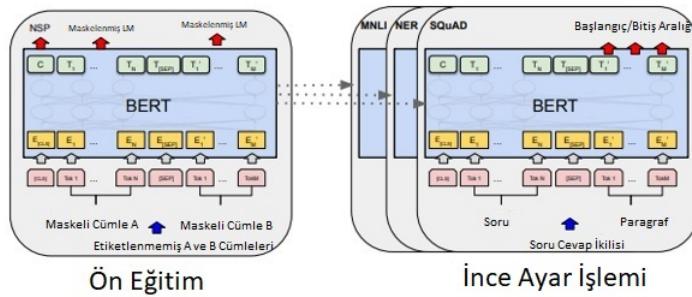
#### 5.2.6.1 BERT öncesi eğitim

BERT, iki farklı ancak ilişkili NLP görevi olan maskelenmiş dil modelleme (MLM) ve sonraki cümle tahmini (NSP) ile önceden eğitilmiştir. MLM'nin amacı, bir cümlede bir kelimeyi gizleyip programın gizlenen kelimeyi bağlamına göre tahmin etmesini sağlamaktır. NSP'nin amacı, iki verilen cümlenin mantıksal ve sıralı bir bağlantıya sahip olup olmadığını veya ilişkilerinin rastgele olup olmadığını tahmin etmektir.

### 5.2.6.2 BERT'in ince ayarı

BERT, ön eğitimden sonra belirli NLP görevleri için ince ayarlar yapılmaktadır. İnce ayar sırasında model, ilgili görevye özgü yeni bir katman eklenerek eğitilir. Bu, modeli duyu analizi, soru-cevap ve adlandırılmış varlık tanıma gibi görevlerde daha etkili ve gereksinimlere uygun hale getirmektedir.

Bu eğitim süreçlerine ait görselleştirme Şekil 5.7'de ifade edilmiştir.



Şekil 5.7 BERT eğitim süreci [14]

### 5.2.7 RoBERTa

RoBERTa, BERT'in basit ama çok popüler bir alternatifidir. Öncelikle BERT'in eğitim hiperparametrelerini dikkatli ve ayrıntılı biçimde optimize ederek iyileştirmektedir. Birkaç basit ve doğrudan değişiklik ile RoBERTa'nın performansı artıyor ve BERT'in çözdüğü hemen hemen tüm görevlerde BERT'i geride bırakmasını sağlamaktadır [15]. Tam anlamıyla BERT ile aynı mimariyi kullanmaktadır. Ancak BERT'ten farklı olarak, ön eğitim süreci yalnızca MLM ile eğitilmiştir.

### 5.2.8 ALBERT

ALBERT, BERT'in bir alternatif olup daha verimli sonuçlar üreten bir modeldir. BERT'in tüm bağlantıları aynı boyutta olduğu halde, ALBERT'de bu boyut azaltılarak modelin daha hafif olması sağlanmıştır. Bu küçültme işlemi, ALBERT'in daha az parametreyle daha yüksek performans göstermesini sağlamaktadır. Ayrıca, ALBERT, farklı boyutlardaki dikkat başlıklarını kullanarak eğitilmektedir. Bu, ALBERT'in daha etkili bir şekilde öğrenmesini sağlamakta ve daha az hesaplama gücü gerektirmektedir.

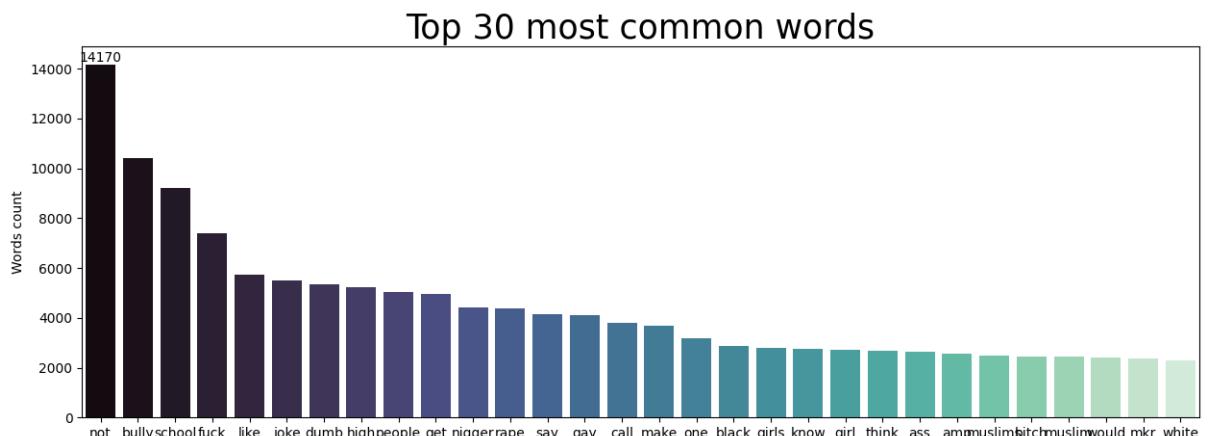
# 6

## Uygulama

Bu bölümde kullanılan modeller ve elde edilen sonuçlar hakkında bilgi verilmektedir. Proje kapsamında siber zorbalık tespiti için iki farklı kategoride çalışılmaktadır.

### 6.1 Veri Setinde En Sık Kullanılan Kelimeler

Ön işleme aşamasından sonra veri setinde en sık kullanılan 30 kelime Şekil 6.1'de ifade edilmiştir.



Şekil 6.1 En Sık Bulunan 30 Kelime

### 6.2 Veri Seti ve Kategoriler

Projede 47.692 adet twitter mesajlarından oluşan bir veri seti kullanılmıştır.

#### 6.2.1 Binary Set

Bu veri seti 47.692 adet twitter mesajı içeren veri setinden küçültülverek elde edilmiştir. Elde edilen veri seti 13.946 satır uzunluğundadır. Veri setinde bulunan sınıflar aşağıda verilmiştir.

- 0 - Siber Zorbalık Değil
- 1 - Siber Zorbalık

### 6.2.2 Farklı Kategorili Sınıflandırma

Burada veri setinde herhangi bir değişiklik yapılmamıştır. Veri setinde bulunan sınıflar aşağıda belirtilmiştir.

- 0 - Siber Zorbalık Değil
- 1 - Din
- 2 - Cinsiyet
- 3 - Irk
- 4 - Yaş
- 5 - Diğer Siber Zorbalıklar

## 6.3 Model Eğitimi

Kullanılan derin öğrenme modelleri güçlü bilgisayar sistemleri gerektirdiğinden Google Colab kullanılarak modellerin eğitimi gerçekleştirilmiştir. Kullanılan derin öğrenme modelleri Kısa Uzun Süreli Bellek (LSTM), BERT, ALBERT, Roberta'dır.

Modellerin eğitiminde çok fazla zaman geçmesi sebebiyle vektör boyutları küçültülmeye gidilmiştir. Bunun yanında işlemci gücü yetersiz kaldığı için derin öğrenme modelleri eğitiminde ekran kartından faydalanyanmıştır.

Uzun Kısa Süreli Bellek (LSTM) modeli için 3 farklı yöntemle vektörler oluşturulmuştur. Bunlar Word2Vec, FastText ve BERT modelinin çıktı verdiği vektörlerdir.

- Word2Vec - Doğal dil işlemede sıkça kullanılan bir tekniktir. Bu model benzer anlamlı kelimeleri sayısal olarak birbirlerine olabildiğince yakın bir şekilde modellemeye çalışır. Temel amacı olarak kelimeleri yüksek boyutlu vektörler olarak temsil etmek söylenebilir.
- FastText - Facebook AI Research tarafından geliştirilmiştir. Word2Vec'in çalışmasına çok benzer fakat bazı farklar bulunmaktadır. En büyük farklılık

olarak kelimelerin alt parçalarını dikkate alır. Örnek olarak, "which" kelimesi için "wh", "whi", "hic" gibi bir çok alt parçayı dikkate alır.

- BERT Vektörleri - BERT modelinden elde edilen vektörler LSTM modeline verilmiştir.

Modeller farklı sayıdaki epochlarda çalıştırılmışlardır. Eğer artış durmadıysa epoch değeri arttırılarak tekrar çalıştırılmıştır. En son olarak 30 epocha kadar çıkışmıştır.

# 7 Deneysel Sonuçlar

---

Bu bölümde projemiz kapsamında elde edilen deneysel sonuçlar gösterilmektedir.

## 7.1 Kullanılan Veri Setinin Seçimi

Proje kapsamında birçok farklı veri seti denenmiştir. Bu veri setleri OLID 2019 [16], Hate Speech Identification [17], Cyberbullying Classification'dır [5]. Bu veri setlerinin hepsi ile makine öğrenmesi algoritmaları denenmiştir. Yapılan deneyler sonucunda diğer iki veri setinin Cyberbullying Classification isimli veri setinden elde edilen sonuçlardan çok daha düşük olduğu gözlemlenmiştir. Bu sebeple proje boyunca bu veri seti kullanılmıştır.

Bu veri setlerinin tamamı Twitter üzerinden toplanmış ingilizce yorum metinlerinden oluşmaktadır. Alınan sonuçların farklı çıkma sebebi olarak toplanan twitter sayfalarının farklılıklarını, toplanan mesajların uzunluğu, sınıflandırma aşamasının kalite farklılığını düşünülmektedir.

Tablo 7.1'de veri setlerinden Destek Vektör Makineleri ve Lojistik Regresyon ile elde edilen doğruluk oranı verilmiştir.

**Tablo 7.1** Veri Setlerindeki Doğruluk Oranları

Veri Seti	SVM	LR
OLID 2019	0.68	0.70
Hate Speech Identification	0.66	0.69
Cyberbullying Classification	0.83	0.84

## 7.2 Veri Setindeki Değişiklikler

Proje yapılrken kullanılan veri setinde ilk başta hiçbir değişiklik yapılmamıştır. Fakat "Diğer Siber Zorbalık" isimli sınıf incelendiğinde içeriğindeki cümlelerin siber zirbelik olarak değerlendirilemeyeceği kanısına varılmıştır. Bunun sonucunda bu sınıfı veri

setinde çıkarıp sonuçların incelenmesi kararı verilmiştir. Bu deney aşamasında Lojistik Regresyon, SVM, Çok Terimli Naive Bayes ve KNN algoritmaları kullanılmıştır.

Tablo 7.2'de bu işlem gerçekleştirilmeden önce ve gerçekleştirildikten sonra elde edilen doğruluk oranları verilmiştir.

**Tablo 7.2** Veri Setlerindeki Doğruluk Oranları

Veri Seti Hali	SVM	LR	KNN	MNB
İlk Hali	0.83	0.84	0.74	0.79
Son Hali	0.91	0.91	0.84	0.87

Yapılan deney sonucunda "Diğer Siber Zorbalık" isimli sınıfın projenin devamında kullanılması kararı verilmiştir.

# 8

## Performans Analizi

Bu bölümde proje boyunca kullanılan modellerin göstermiş oldukları performansların analizi verilmektedir.

### 8.1 Erken Çıktılar

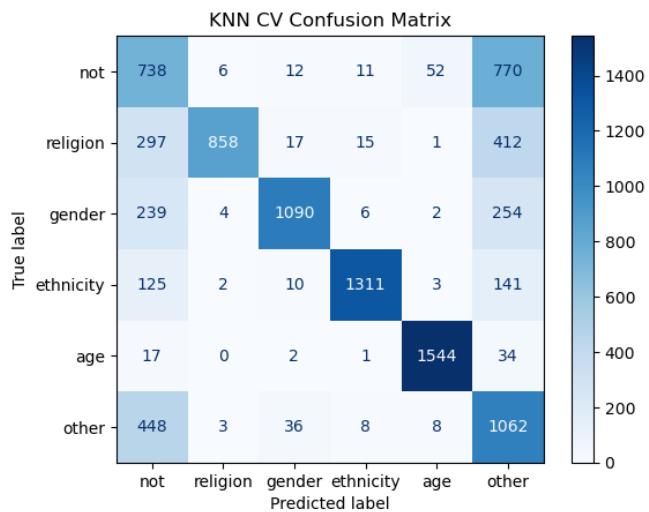
Bu bölümde veri setinden "Diğer Siber Zorbalıklar" sınıfı çıkarılmadan önceki sonuçlara yer verilmiştir. Projede erken geliştirme aşamasında 4 adet makine öğrenmesi algoritması kullanılmıştır. Bu makine öğrenme algoritmaları iki farklı vektörleştirme metoduyla çalıştırılıp test edilmiştir. Vektörleştirmek için Count Vectorizer ve Tf-Idf Vectorizer kullanılmıştır. Tüm kategorilerde yapılan karşılaştırma için kullanılan veri seti 47.692 satır, iki kategorili karşılaştırma için kullanılan veri seti ise 13.946 satırdan oluşmaktadır.

#### 8.1.1 K En Yakın Komşular

KNN kullanılarak elde edilen sonuçlar Şekil 8.1, Şekil 8.3, Şekil 8.5, Şekil 8.7, Şekil 8.2, Şekil 8.4, Şekil 8.6, Şekil 8.8'lerde görülmektedir.

	precision	recall	f1-score	support
age	0.96	0.97	0.96	1598
ethnicity	0.97	0.82	0.89	1592
gender	0.93	0.68	0.79	1595
not_cyberbullying	0.40	0.46	0.43	1589
other_cyberbullying	0.40	0.68	0.50	1565
religion	0.98	0.54	0.69	1600
accuracy			0.69	9539
macro avg	0.77	0.69	0.71	9539
weighted avg	0.77	0.69	0.71	9539

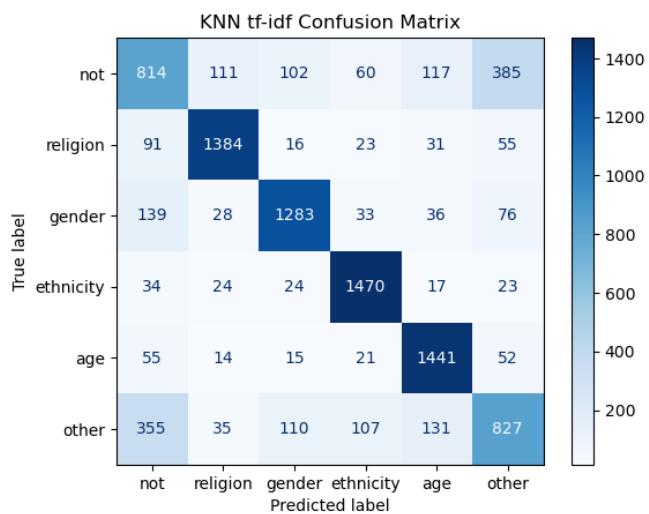
Şekil 8.1 KNN CV Tüm Kategoriler Model Performansı



**Şekil 8.2** KNN CV Tüm Kategoriler

	precision	recall	f1-score	support
age	0.81	0.90	0.85	1598
ethnicity	0.86	0.92	0.89	1592
gender	0.83	0.80	0.82	1595
not_cyberbullying	0.55	0.51	0.53	1589
other_cyberbullying	0.58	0.53	0.55	1565
religion	0.87	0.86	0.87	1600
accuracy			0.76	9539
macro avg	0.75	0.76	0.75	9539
weighted avg	0.75	0.76	0.75	9539

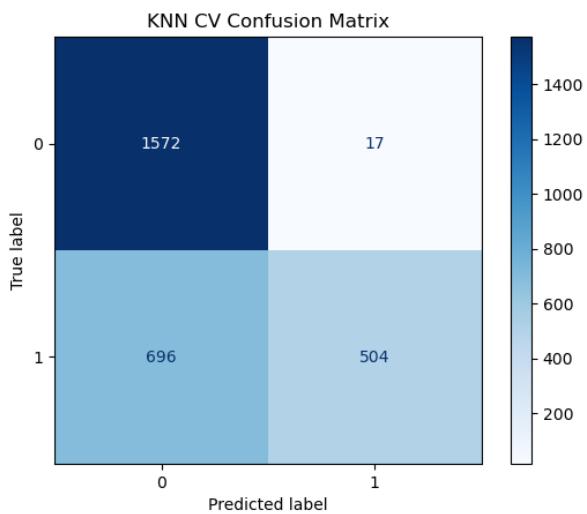
**Şekil 8.3** KNN TF-IDF Tüm Kategoriler Model Performansı



**Şekil 8.4** KNN TF-IDF Tüm Kategoriler

	precision	recall	f1-score	support
0	0.69	0.99	0.82	1589
1	0.97	0.42	0.59	1200
accuracy			0.74	2789
macro avg	0.83	0.70	0.70	2789
weighted avg	0.81	0.74	0.72	2789

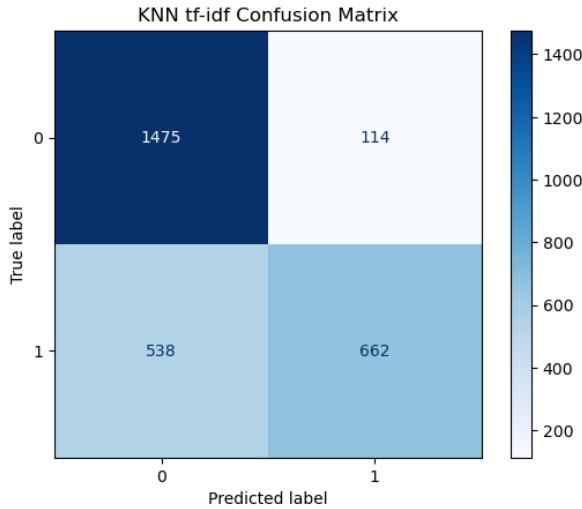
Şekil 8.5 KNN CV İki Kategori Model Performansı



Şekil 8.6 KNN CV İki Kategori

	precision	recall	f1-score	support
0	0.73	0.93	0.82	1589
1	0.85	0.55	0.67	1200
accuracy			0.77	2789
macro avg	0.79	0.74	0.74	2789
weighted avg	0.78	0.77	0.75	2789

Şekil 8.7 KNN TF-IDF İki Kategori Model Performansı



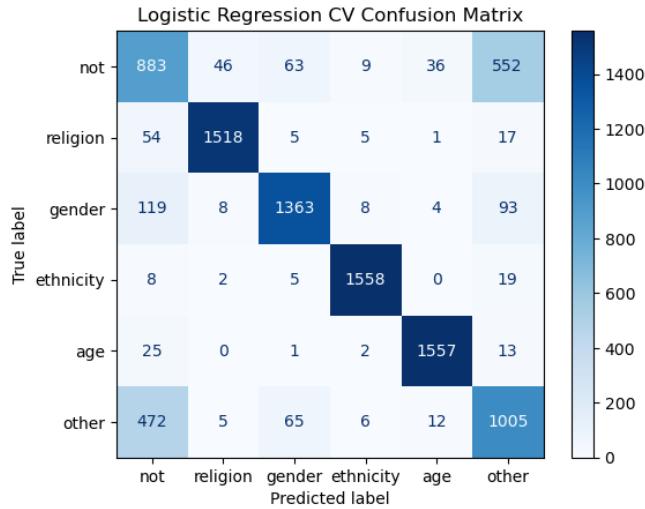
**Şekil 8.8** KNN TF-IDF İki Kategori

### 8.1.2 Lojistik Regresyon

Lojistik Regresyon kullanılarak elde edilen sonuçlar Şekil 8.9, Şekil 8.11, Şekil 8.13, Şekil 8.15, Şekil 8.10, Şekil 8.12, Şekil 8.14, Şekil 8.16'lerde görülmektedir.

	precision	recall	f1-score	support
age	0.97	0.97	0.97	1598
ethnicity	0.98	0.98	0.98	1592
gender	0.91	0.85	0.88	1595
not_cyberbullying	0.57	0.56	0.56	1589
other_cyberbullying	0.59	0.64	0.62	1565
religion	0.96	0.95	0.96	1600
accuracy			0.83	9539
macro avg	0.83	0.83	0.83	9539
weighted avg	0.83	0.83	0.83	9539

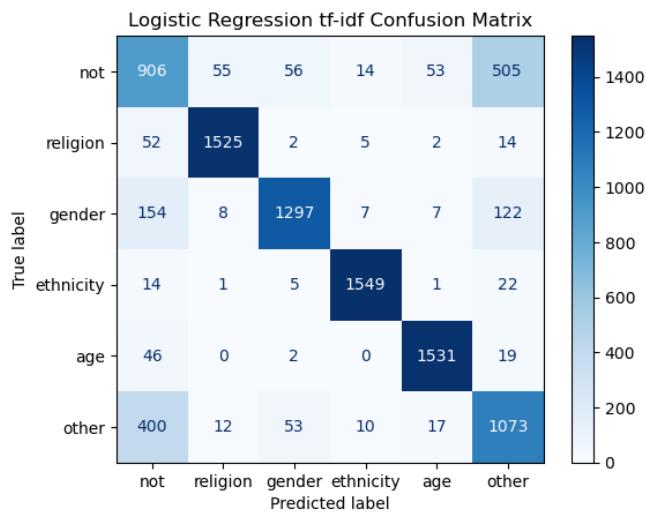
**Şekil 8.9** Lojistik Regresyon CV Tüm Kategoriler Model Performansı



**Şekil 8.10 Lojistik Regresyon CV Tüm Kategoriler**

	precision	recall	f1-score	support
age	0.95	0.96	0.95	1598
ethnicity	0.98	0.97	0.98	1592
gender	0.92	0.81	0.86	1595
not_cyberbullying	0.58	0.57	0.57	1589
other_cyberbullying	0.61	0.69	0.65	1565
religion	0.95	0.95	0.95	1600
accuracy			0.83	9539
macro avg	0.83	0.83	0.83	9539
weighted avg	0.83	0.83	0.83	9539

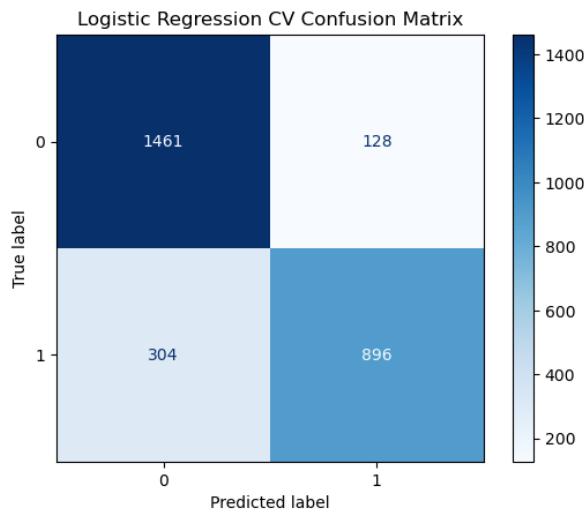
**Şekil 8.11 Lojistik Regresyon TF-IDF Tüm Kategoriler Model Performansı**



**Şekil 8.12 Lojistik Regresyon TF-IDF Tüm Kategoriler**

	precision	recall	f1-score	support
cyberbullying	0.88	0.75	0.81	1200
not_cyberbullying	0.83	0.92	0.87	1589
accuracy			0.85	2789
macro avg	0.85	0.83	0.84	2789
weighted avg	0.85	0.85	0.84	2789

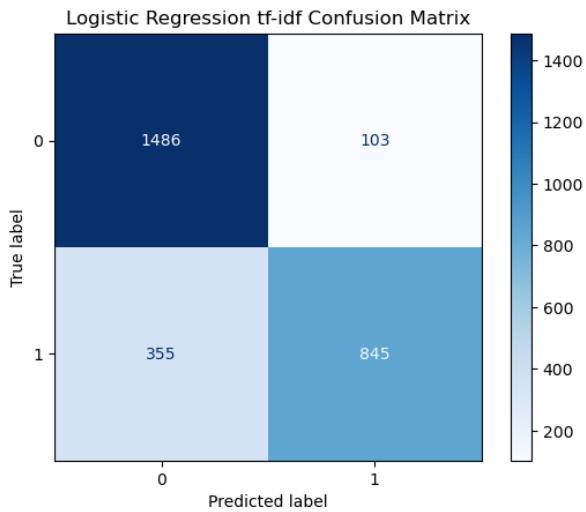
Şekil 8.13 Lojistik Regresyon CV İki Kategori Model Performansı



Şekil 8.14 Lojistik Regresyon CV İki Kategori

	precision	recall	f1-score	support
cyberbullying	0.89	0.70	0.79	1200
not_cyberbullying	0.81	0.94	0.87	1589
accuracy			0.84	2789
macro avg	0.85	0.82	0.83	2789
weighted avg	0.84	0.84	0.83	2789

Şekil 8.15 Lojistik Regresyon TF-IDF İki Kategori Model Performansı



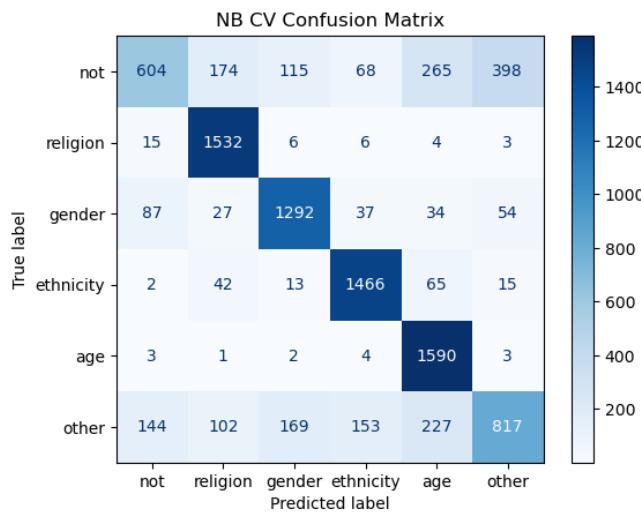
**Şekil 8.16 Lojistik Regresyon TF-IDF İki Kategori**

### 8.1.3 Çok Terimli Naive Bayes

Çok Terimli Naive Bayes kullanılarak elde edilen sonuçlar Şekil 8.17, Şekil 8.19, Şekil 8.21, Şekil 8.23, Şekil 8.18, Şekil 8.20, Şekil 8.22, Şekil 8.24'lerde görülmektedir.

	precision	recall	f1-score	support
age	0.73	0.99	0.84	1603
ethnicity	0.85	0.91	0.88	1603
gender	0.81	0.84	0.83	1531
not_cyberbullying	0.71	0.37	0.49	1624
other_cyberbullying	0.63	0.51	0.56	1612
religion	0.82	0.98	0.89	1566
accuracy			0.77	9539
macro avg	0.76	0.77	0.75	9539
weighted avg	0.76	0.77	0.75	9539

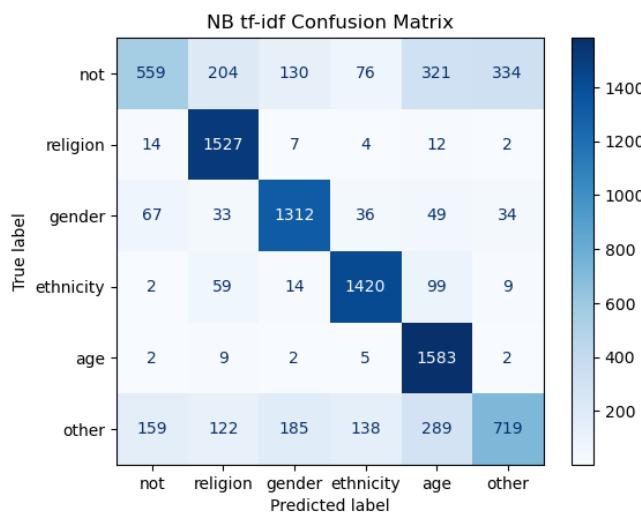
**Şekil 8.17 MNB CV Tüm Kategoriler Model Performansı**



**Şekil 8.18** MNB CV Tüm Kategoriler

	precision	recall	f1-score	support
age	0.67	0.99	0.80	1603
ethnicity	0.85	0.89	0.87	1603
gender	0.80	0.86	0.82	1531
not_cyberbullying	0.70	0.34	0.46	1624
other_cyberbullying	0.65	0.45	0.53	1612
religion	0.78	0.98	0.87	1566
accuracy			0.75	9539
macro avg	0.74	0.75	0.72	9539
weighted avg	0.74	0.75	0.72	9539

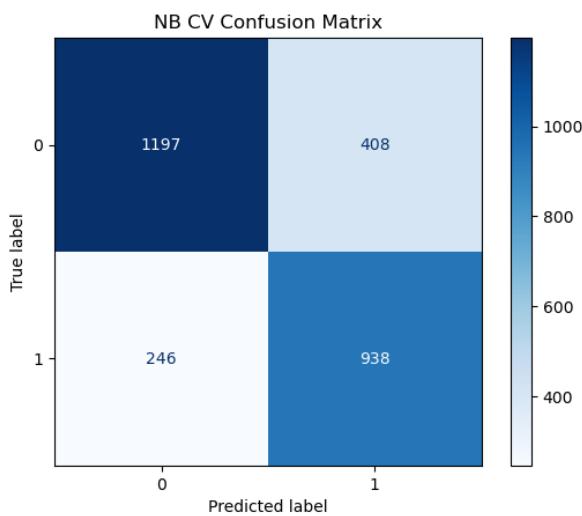
**Şekil 8.19** MNB TF-IDF Tüm Kategoriler Model Performansı



**Şekil 8.20** MNB TF-IDF Tüm Kategoriler

	precision	recall	f1-score	support
cyberbullying	0.70	0.79	0.74	1184
not_cyberbullying	0.83	0.75	0.79	1605
accuracy			0.77	2789
macro avg	0.76	0.77	0.76	2789
weighted avg	0.77	0.77	0.77	2789

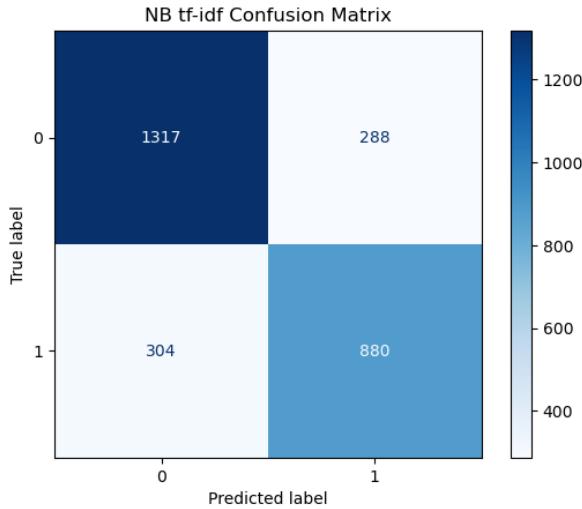
Şekil 8.21 MNB CV İki Kategori Model Performansı



Şekil 8.22 MNB CV İki Kategori

	precision	recall	f1-score	support
cyberbullying	0.75	0.74	0.75	1184
not_cyberbullying	0.81	0.82	0.82	1605
accuracy			0.79	2789
macro avg	0.78	0.78	0.78	2789
weighted avg	0.79	0.79	0.79	2789

Şekil 8.23 MNB TF-IDF İki Kategori Model Performansı



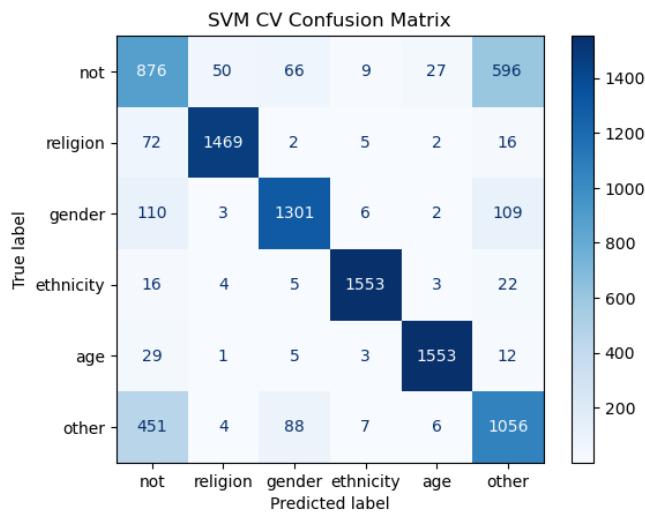
**Şekil 8.24** MNB TF-IDF İki Kategori

#### 8.1.4 Destek Vektör Makineleri

Destek Vektör Makineleri kullanılarak elde edilen sonuçlar Şekil 8.25, Şekil 8.27, Şekil 8.29, Şekil 8.31, Şekil 8.26, Şekil 8.28, Şekil 8.30, Şekil 8.32'lerde görülmektedir.

	precision	recall	f1-score	support
age	0.97	0.97	0.97	1603
ethnicity	0.98	0.97	0.97	1603
gender	0.89	0.85	0.87	1531
not_cyberbullying	0.56	0.54	0.55	1624
other_cyberbullying	0.58	0.66	0.62	1612
religion	0.96	0.94	0.95	1566
accuracy			0.82	9539
macro avg	0.82	0.82	0.82	9539
weighted avg	0.82	0.82	0.82	9539

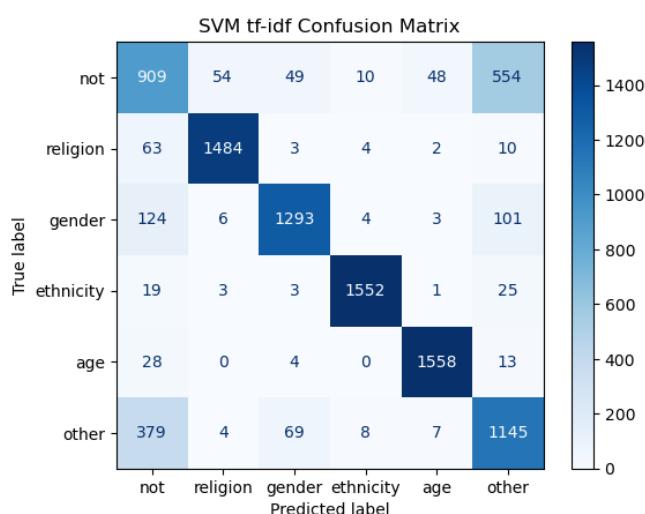
**Şekil 8.25** SVM CV Tüm Kategoriler Model Performansı



Şekil 8.26 SVM CV Tüm Kategoriler

	precision	recall	f1-score	support
age	0.96	0.97	0.97	1603
ethnicity	0.98	0.97	0.98	1603
gender	0.91	0.84	0.88	1531
not_cyberbullying	0.60	0.56	0.58	1624
other_cyberbullying	0.62	0.71	0.66	1612
religion	0.96	0.95	0.95	1566
accuracy			0.83	9539
macro avg	0.84	0.83	0.84	9539
weighted avg	0.84	0.83	0.83	9539

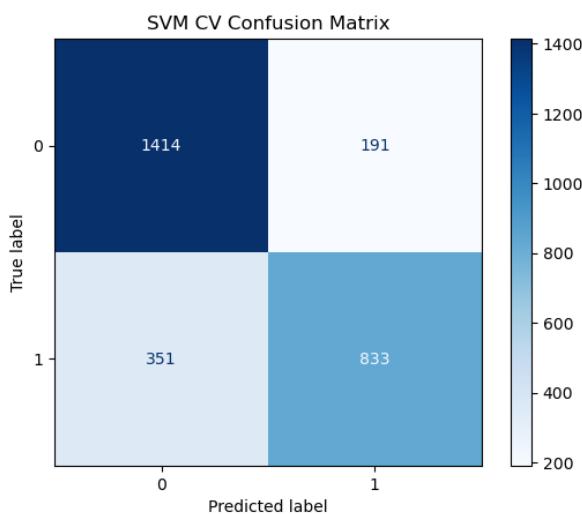
Şekil 8.27 SVM TF-IDF Tüm Kategoriler Model Performansı



Şekil 8.28 SVM TF-IDF Tüm Kategoriler

	precision	recall	f1-score	support
cyberbullying	0.81	0.70	0.75	1184
not_cyberbullying	0.80	0.88	0.84	1605
accuracy			0.81	2789
macro avg	0.81	0.79	0.80	2789
weighted avg	0.81	0.81	0.80	2789

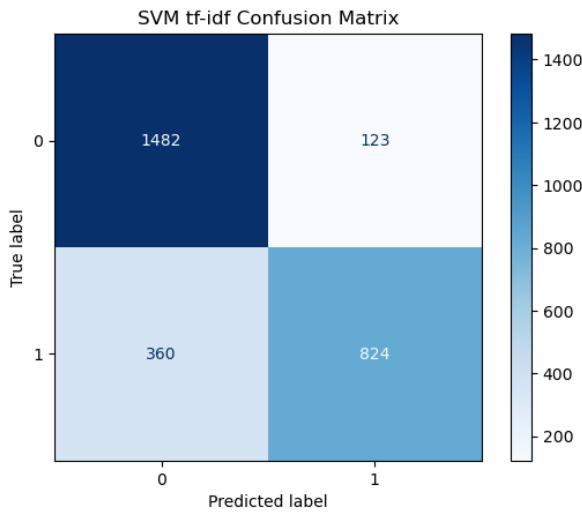
Şekil 8.29 SVM CV İki Kategori Model Performansı



Şekil 8.30 SVM CV İki Kategori

	precision	recall	f1-score	support
cyberbullying	0.87	0.70	0.77	1184
not_cyberbullying	0.80	0.92	0.86	1605
accuracy			0.83	2789
macro avg	0.84	0.81	0.82	2789
weighted avg	0.83	0.83	0.82	2789

Şekil 8.31 SVM TF-IDF İki Kategori Model Performansı



**Şekil 8.32** SVM TF-IDF İki Kategori

## 8.2 Son Çıktılar

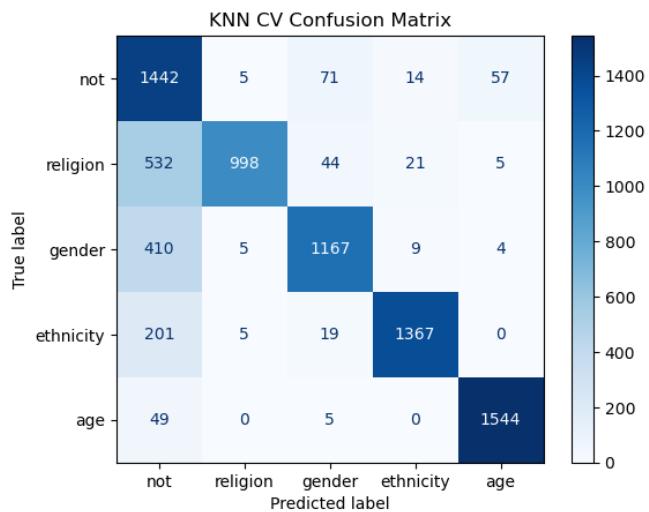
Bu bölümde kullanılan tüm makine öğrenmesi ve derin öğrenme modellerinden alınan en son ve en başarılı sonuçlar verilecektir.

### 8.2.1 K En Yakın Komşular

KNN kullanılarak elde edilen sonuçlar Şekil 8.33, Şekil 8.35, Şekil 8.37, Şekil 8.39, Şekil 8.34, Şekil 8.36, Şekil 8.38, Şekil 8.40'lerde görülmektedir.

	precision	recall	f1-score	support
age	0.96	0.97	0.96	1598
ethnicity	0.97	0.86	0.91	1592
gender	0.89	0.73	0.80	1595
not_cyberbullying	0.55	0.91	0.68	1589
religion	0.99	0.62	0.76	1600
accuracy			0.82	7974
macro avg	0.87	0.82	0.82	7974
weighted avg	0.87	0.82	0.82	7974

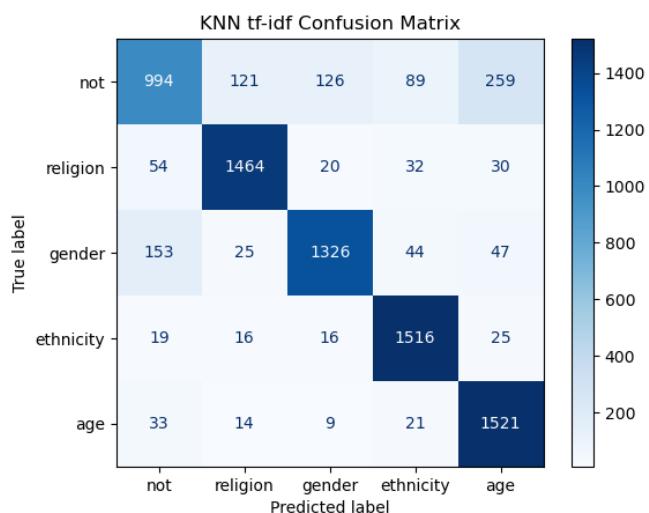
**Şekil 8.33** KNN CV Tüm Kategoriler Model Performansı



**Şekil 8.34** KNN CV Tüm Kategoriler

	precision	recall	f1-score	support
age	0.81	0.95	0.87	1598
ethnicity	0.89	0.95	0.92	1592
gender	0.89	0.83	0.86	1595
not_cyberbullying	0.79	0.63	0.70	1589
religion	0.89	0.92	0.90	1600
accuracy			0.86	7974
macro avg	0.85	0.86	0.85	7974
weighted avg	0.85	0.86	0.85	7974

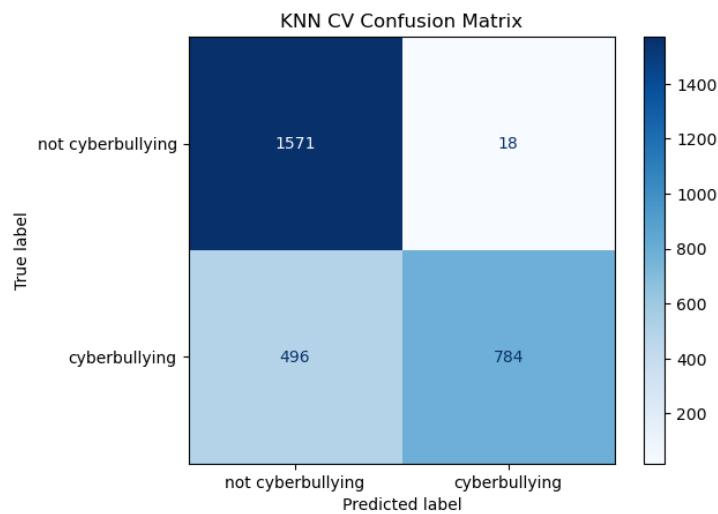
**Şekil 8.35** KNN TF-IDF Tüm Kategoriler Model Performansı



**Şekil 8.36** KNN TF-IDF Tüm Kategoriler

	precision	recall	f1-score	support
0	0.76	0.99	0.86	1589
1	0.98	0.61	0.75	1280
accuracy			0.82	2869
macro avg	0.87	0.80	0.81	2869
weighted avg	0.86	0.82	0.81	2869

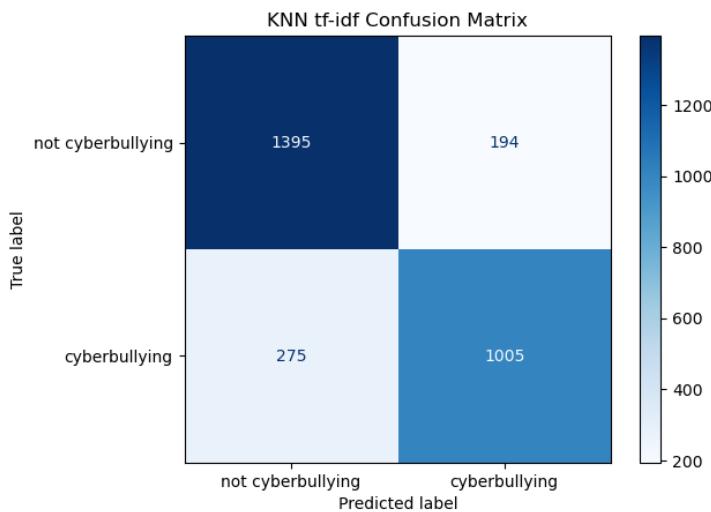
Şekil 8.37 KNN CV İki Kategori Model Performansı



Şekil 8.38 KNN CV İki Kategori

	precision	recall	f1-score	support
0	0.84	0.88	0.86	1589
1	0.84	0.79	0.81	1280
accuracy			0.84	2869
macro avg	0.84	0.83	0.83	2869
weighted avg	0.84	0.84	0.84	2869

Şekil 8.39 KNN TF-IDF İki Kategori Model Performansı



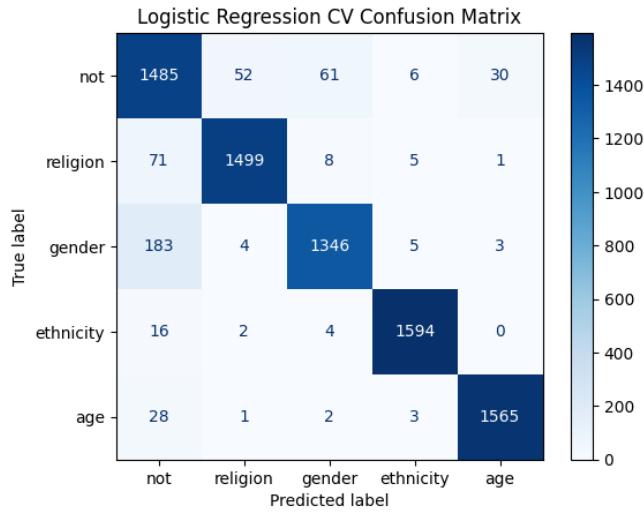
**Şekil 8.40** KNN TF-IDF İki Kategori

### 8.2.2 Lojistik Regresyon

Lojistik Regresyon kullanılarak elde edilen sonuçlar Şekil 8.41, Şekil 8.43, Şekil 8.45, Şekil 8.47, Şekil 8.42, Şekil 8.44, Şekil 8.46, Şekil 8.48'lerde görülmektedir.

	precision	recall	f1-score	support
age	0.98	0.98	0.98	1599
ethnicity	0.99	0.99	0.99	1616
gender	0.95	0.87	0.91	1541
not_cyberbullying	0.83	0.91	0.87	1634
religion	0.96	0.95	0.95	1584
accuracy			0.94	7974
macro avg	0.94	0.94	0.94	7974
weighted avg	0.94	0.94	0.94	7974

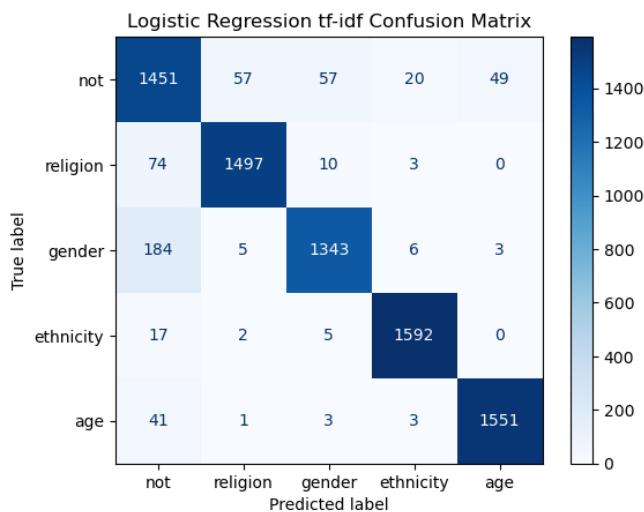
**Şekil 8.41** Lojistik Regresyon CV Tüm Kategoriler Model Performansı



**Şekil 8.42** Lojistik Regresyon CV Tüm Kategoriler

	precision	recall	f1-score	support
age	0.97	0.97	0.97	1599
ethnicity	0.98	0.99	0.98	1616
gender	0.95	0.87	0.91	1541
not_cyberbullying	0.82	0.89	0.85	1634
religion	0.96	0.95	0.95	1584
accuracy			0.93	7974
macro avg	0.93	0.93	0.93	7974
weighted avg	0.93	0.93	0.93	7974

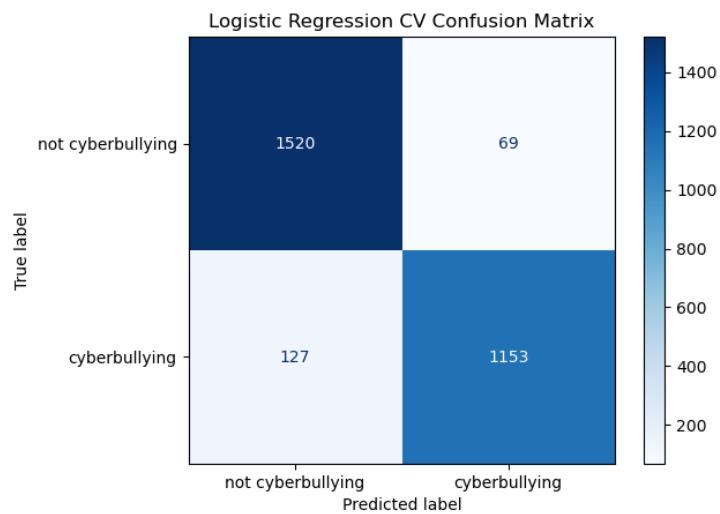
**Şekil 8.43** Lojistik Regresyon TF-IDF Tüm Kategoriler Model Performansı



**Şekil 8.44** Lojistik Regresyon TF-IDF Tüm Kategoriler

	precision	recall	f1-score	support
cyberbullying	0.94	0.90	0.92	1280
not_cyberbullying	0.92	0.96	0.94	1589
accuracy			0.93	2869
macro avg	0.93	0.93	0.93	2869
weighted avg	0.93	0.93	0.93	2869

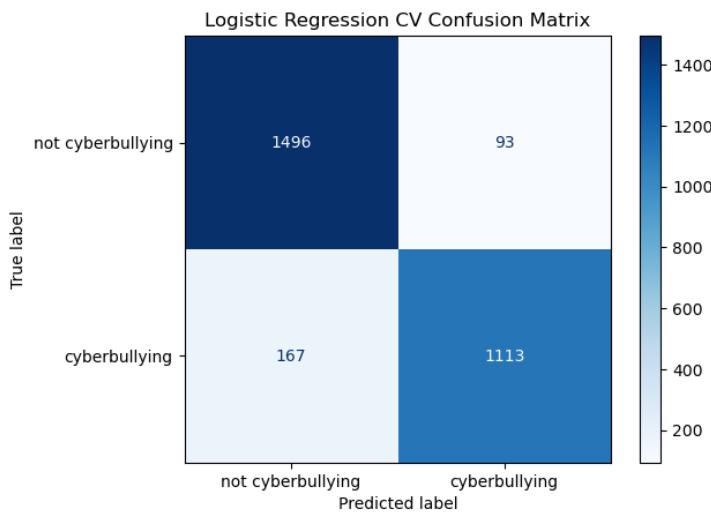
Şekil 8.45 Lojistik Regresyon CV İki Kategori Model Performansı



Şekil 8.46 Lojistik Regresyon CV İki Kategori

	precision	recall	f1-score	support
cyberbullying	0.92	0.87	0.90	1280
not_cyberbullying	0.90	0.94	0.92	1589
accuracy			0.91	2869
macro avg	0.91	0.91	0.91	2869
weighted avg	0.91	0.91	0.91	2869

Şekil 8.47 Lojistik Regresyon TF-IDF İki Kategori Model Performansı



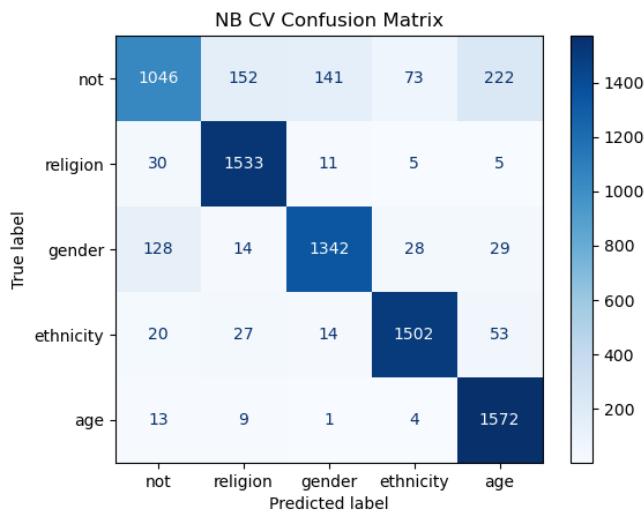
**Şekil 8.48** Lojistik Regresyon TF-IDF İki Kategori

### 8.2.3 Çok Terimli Naive Bayes

Çok Terimli Naive Bayes kullanılarak elde edilen sonuçlar Şekil 8.49, Şekil 8.51, Şekil 8.53, Şekil 8.55, Şekil 8.50, Şekil 8.52, Şekil 8.54, Şekil 8.56'lerde görülmektedir.

	precision	recall	f1-score	support
age	0.84	0.98	0.90	1599
ethnicity	0.93	0.93	0.93	1616
gender	0.89	0.87	0.88	1541
not_cyberbullying	0.85	0.64	0.73	1634
religion	0.88	0.97	0.92	1584
accuracy			0.88	7974
macro avg	0.88	0.88	0.87	7974
weighted avg	0.88	0.88	0.87	7974

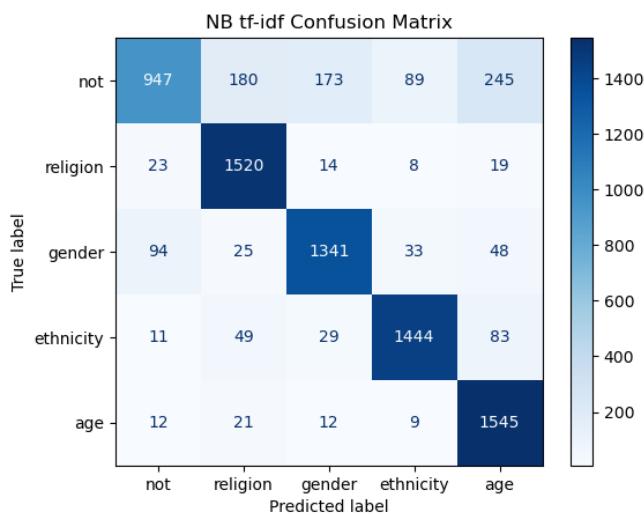
**Şekil 8.49** MNB CV Tüm Kategoriler Model Performansı



**Şekil 8.50 MNB CV Tüm Kategoriler**

	precision	recall	f1-score	support
age	0.80	0.97	0.87	1599
ethnicity	0.91	0.89	0.90	1616
gender	0.85	0.87	0.86	1541
not_cyberbullying	0.87	0.58	0.70	1634
religion	0.85	0.96	0.90	1584
accuracy			0.85	7974
macro avg	0.86	0.85	0.85	7974
weighted avg	0.86	0.85	0.85	7974

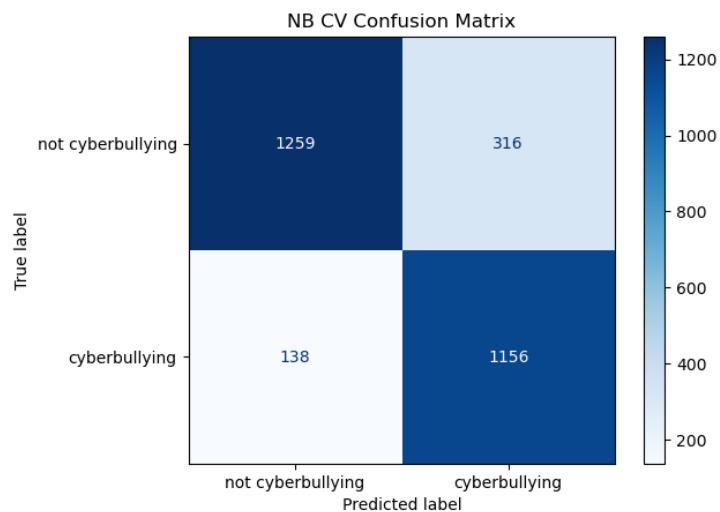
**Şekil 8.51 MNB TF-IDF Tüm Kategoriler Model Performansı**



**Şekil 8.52 MNB TF-IDF Tüm Kategoriler**

	precision	recall	f1-score	support
cyberbullying	0.79	0.89	0.84	1294
not_cyberbullying	0.90	0.80	0.85	1575
accuracy			0.84	2869
macro avg	0.84	0.85	0.84	2869
weighted avg	0.85	0.84	0.84	2869

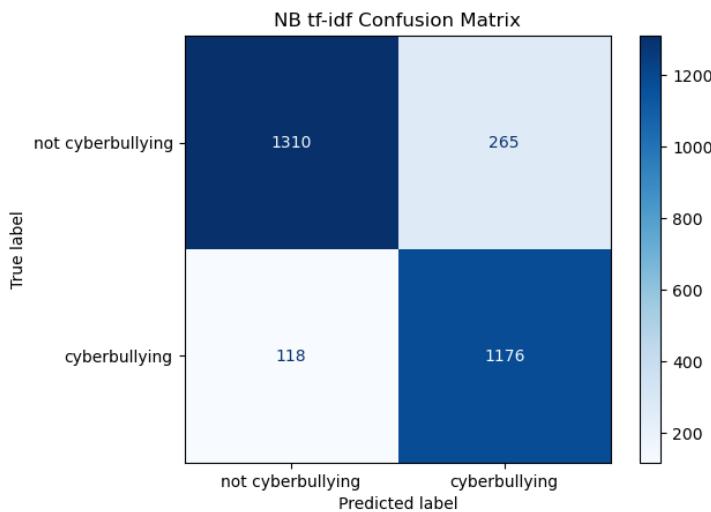
Şekil 8.53 MNB CV İki Kategori Model Performansı



Şekil 8.54 MNB CV İki Kategori

	precision	recall	f1-score	support
cyberbullying	0.82	0.91	0.86	1294
not_cyberbullying	0.92	0.83	0.87	1575
accuracy			0.87	2869
macro avg	0.87	0.87	0.87	2869
weighted avg	0.87	0.87	0.87	2869

Şekil 8.55 MNB TF-IDF İki Kategori Model Performansı



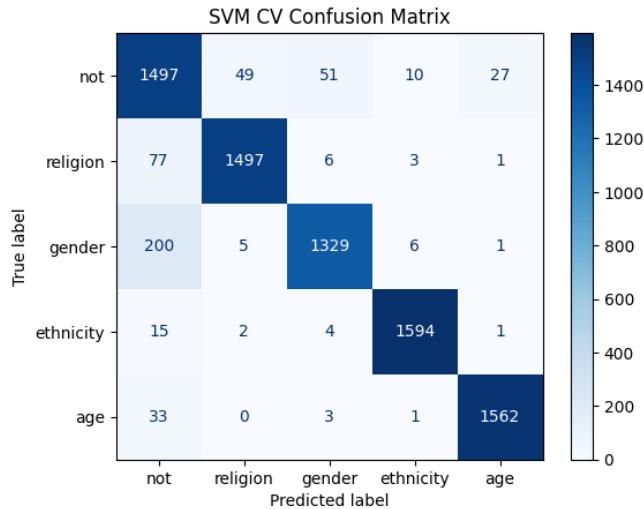
**Şekil 8.56** MNB TF-IDF İki Kategori

#### 8.2.4 Destek Vektör Makineleri

Destek Vektör Makineleri kullanılarak elde edilen sonuçlar Şekil 8.57, Şekil 8.59, Şekil 8.61, Şekil 8.63, Şekil 8.58, Şekil 8.60, Şekil 8.62, Şekil 8.64'lerde görülmektedir.

	precision	recall	f1-score	support
age	0.98	0.98	0.98	1599
ethnicity	0.99	0.99	0.99	1616
gender	0.95	0.86	0.91	1541
not_cyberbullying	0.82	0.92	0.87	1634
religion	0.96	0.95	0.95	1584
accuracy			0.94	7974
macro avg	0.94	0.94	0.94	7974
weighted avg	0.94	0.94	0.94	7974

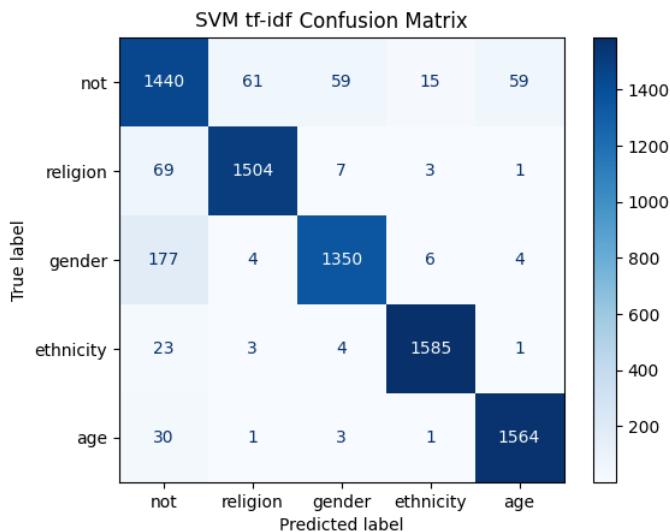
**Şekil 8.57** SVM CV Tüm Kategoriler Model Performansı



**Şekil 8.58** SVM CV Tüm Kategoriler

	precision	recall	f1-score	support
age	0.96	0.98	0.97	1599
ethnicity	0.98	0.98	0.98	1616
gender	0.95	0.88	0.91	1541
not_cyberbullying	0.83	0.88	0.85	1634
religion	0.96	0.95	0.95	1584
accuracy			0.93	7974
macro avg	0.94	0.93	0.93	7974
weighted avg	0.93	0.93	0.93	7974

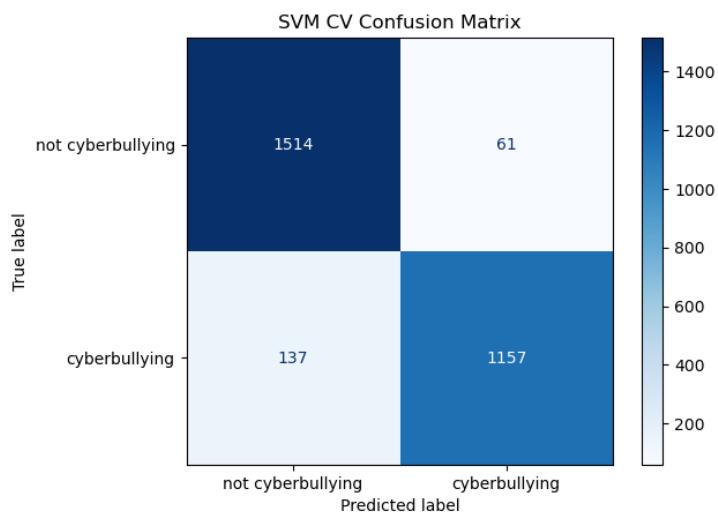
**Şekil 8.59** SVM TF-IDF Tüm Kategoriler Model Performansı



**Şekil 8.60** SVM TF-IDF Tüm Kategoriler

	precision	recall	f1-score	support
cyberbullying	0.95	0.89	0.92	1294
not_cyberbullying	0.92	0.96	0.94	1575
accuracy			0.93	2869
macro avg	0.93	0.93	0.93	2869
weighted avg	0.93	0.93	0.93	2869

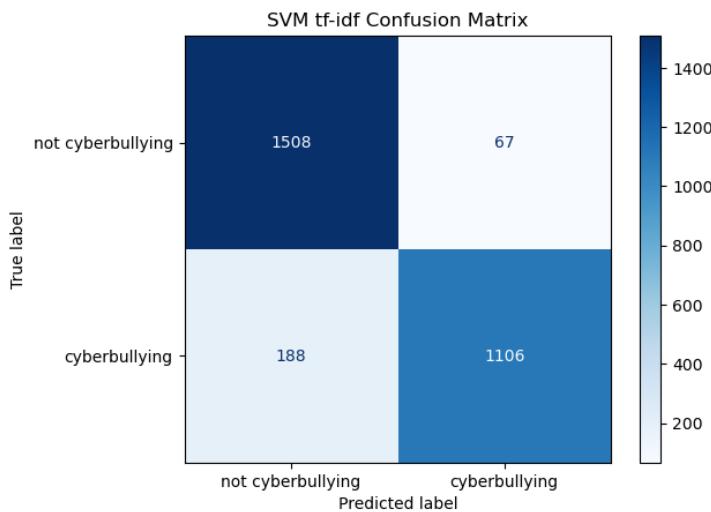
Şekil 8.61 SVM CV İki Kategori Model Performansı



Şekil 8.62 SVM CV İki Kategori

	precision	recall	f1-score	support
cyberbullying	0.94	0.85	0.90	1294
not_cyberbullying	0.89	0.96	0.92	1575
accuracy			0.91	2869
macro avg	0.92	0.91	0.91	2869
weighted avg	0.91	0.91	0.91	2869

Şekil 8.63 SVM TF-IDF İki Kategori Model Performansı



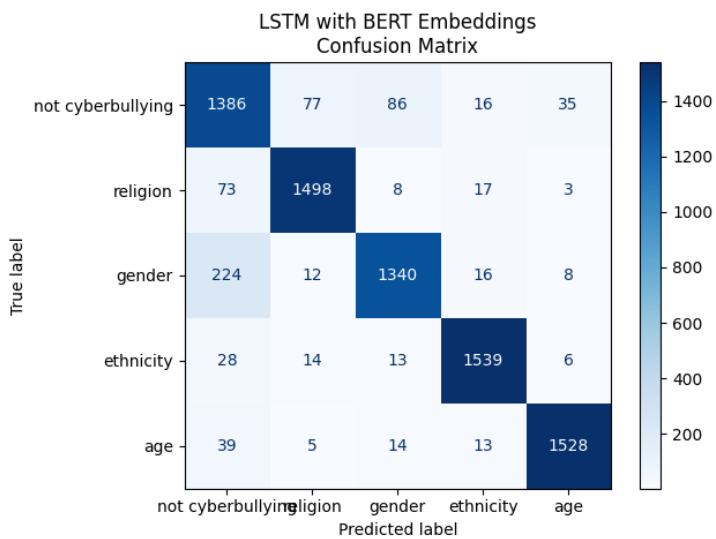
**Şekil 8.64** SVM TF-IDF İki Kategori

### 8.2.5 Uzun Kısa Süreli Bellek (LSTM)

Bu model çalıştırılırken 3 farklı vektörleştirme metodu denenmiştir. Bunlar Word2Vec, FastText ve BERT çıktıları vektörlerdir. Uzun Kısa Süreli Bellek kullanılarak elde edilen sonuçlar Şekil 8.65, Şekil 8.67, Şekil 8.69, Şekil 8.71, Şekil 8.73, Şekil 8.75, Şekil 8.66, Şekil 8.68, Şekil 8.70, Şekil 8.72, Şekil 8.74, Şekil 8.76'lerde görülmektedir.

	precision	recall	f1-score	support
not cyberbullying	0.79	0.87	0.83	1600
religion	0.93	0.94	0.93	1599
gender	0.92	0.84	0.88	1600
ethnicity	0.96	0.96	0.96	1600
age	0.97	0.96	0.96	1599
accuracy			0.91	7998
macro avg	0.91	0.91	0.91	7998
weighted avg	0.91	0.91	0.91	7998

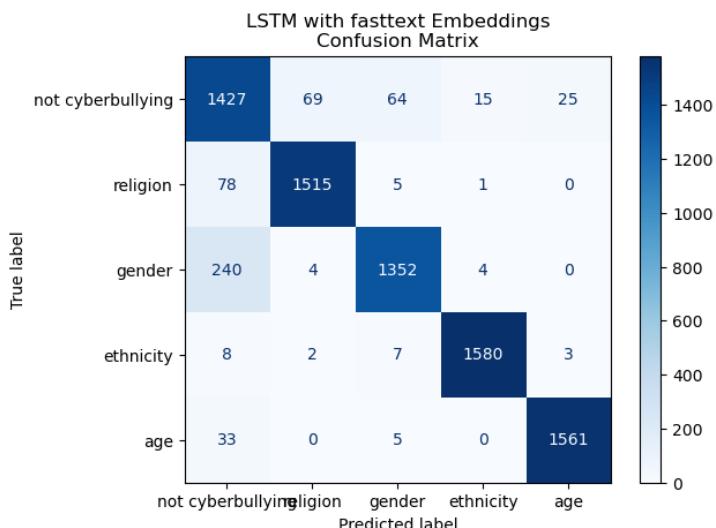
**Şekil 8.65** LSTM BERT vektörleştirme Tüm Kategoriler Model Performansı



**Şekil 8.66** LSTM BERT Tüm Kategoriler

	precision	recall	f1-score	support
<b>not cyberbullying</b>	0.80	0.89	0.84	1600
<b>religion</b>	0.95	0.95	0.95	1599
<b>gender</b>	0.94	0.84	0.89	1600
<b>ethnicity</b>	0.99	0.99	0.99	1600
<b>age</b>	0.98	0.98	0.98	1599
<b>accuracy</b>			0.93	7998
<b>macro avg</b>	0.93	0.93	0.93	7998
<b>weighted avg</b>	0.93	0.93	0.93	7998

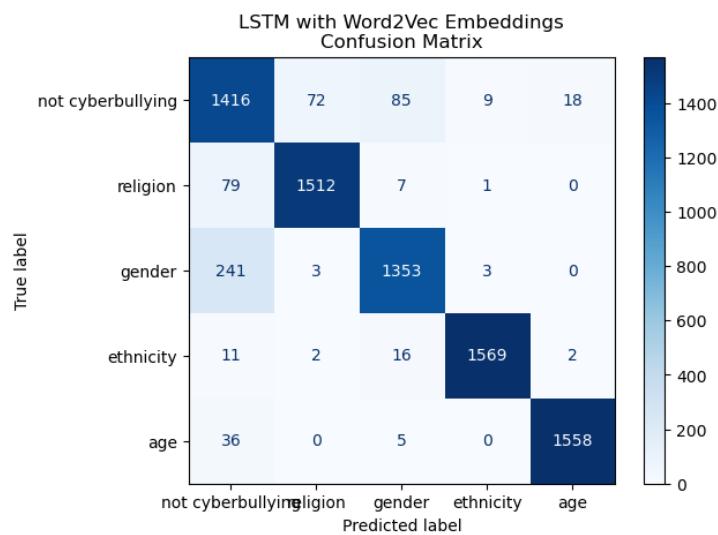
**Şekil 8.67** LSTM FastText Tüm Kategoriler Model Performansı



**Şekil 8.68** LSTM FastText Tüm Kategoriler

	precision	recall	f1-score	support
not cyberbullying	0.79	0.89	0.84	1600
religion	0.95	0.95	0.95	1599
gender	0.92	0.85	0.88	1600
ethnicity	0.99	0.98	0.99	1600
age	0.99	0.97	0.98	1599
accuracy			0.93	7998
macro avg	0.93	0.93	0.93	7998
weighted avg	0.93	0.93	0.93	7998

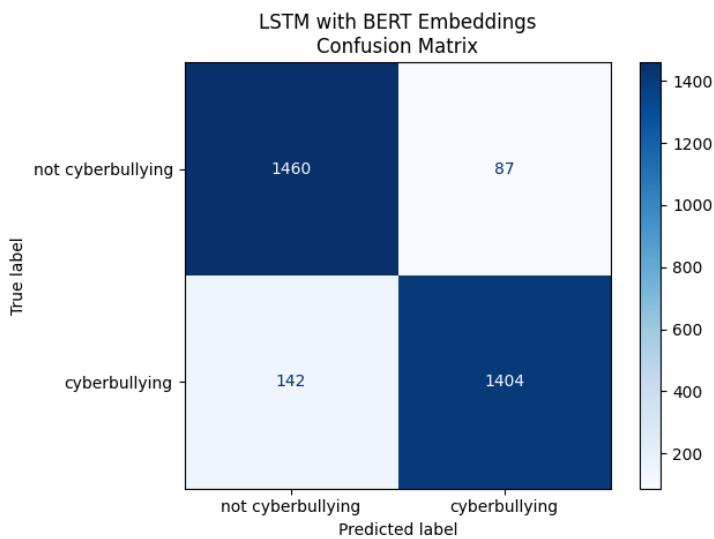
Şekil 8.69 LSTM Word2Vec vektörleştirme Tüm Kategoriler Model Performansı



Şekil 8.70 LSTM Word2Vec Tüm Kategoriler

	precision	recall	f1-score	support
not cyberbullying	0.91	0.94	0.93	1547
cyberbullying	0.94	0.91	0.92	1546
accuracy			0.93	3093
macro avg	0.93	0.93	0.93	3093
weighted avg	0.93	0.93	0.93	3093

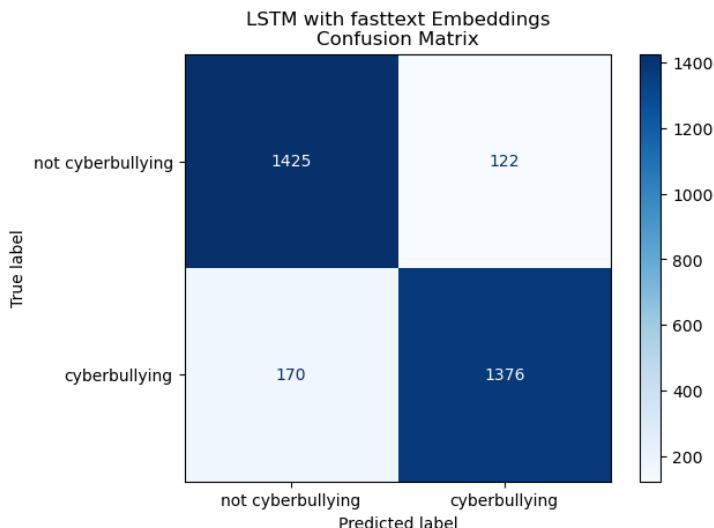
Şekil 8.71 LSTM BERT vektörleştirme İki Kategori Model Performansı



**Şekil 8.72** LSTM BERT İki Kategori

	precision	recall	f1-score	support
not cyberbullying	0.89	0.92	0.91	1547
cyberbullying	0.92	0.89	0.90	1546
accuracy			0.91	3093
macro avg	0.91	0.91	0.91	3093
weighted avg	0.91	0.91	0.91	3093

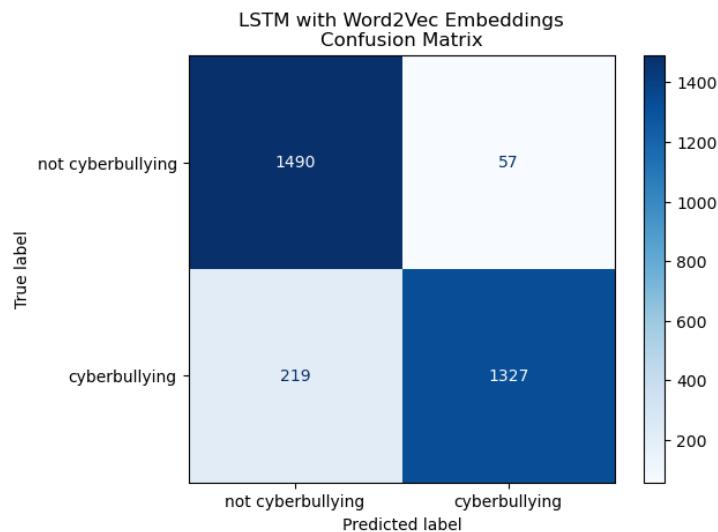
**Şekil 8.73** LSTM FastText İki Kategori Model Performansı



**Şekil 8.74** LSTM FastText İki Kategori

	precision	recall	f1-score	support
not cyberbullying	0.87	0.96	0.92	1547
cyberbullying	0.96	0.86	0.91	1546
accuracy			0.91	3093
macro avg	0.92	0.91	0.91	3093
weighted avg	0.92	0.91	0.91	3093

Şekil 8.75 LSTM Word2Vec İki Kategori Model Performansı



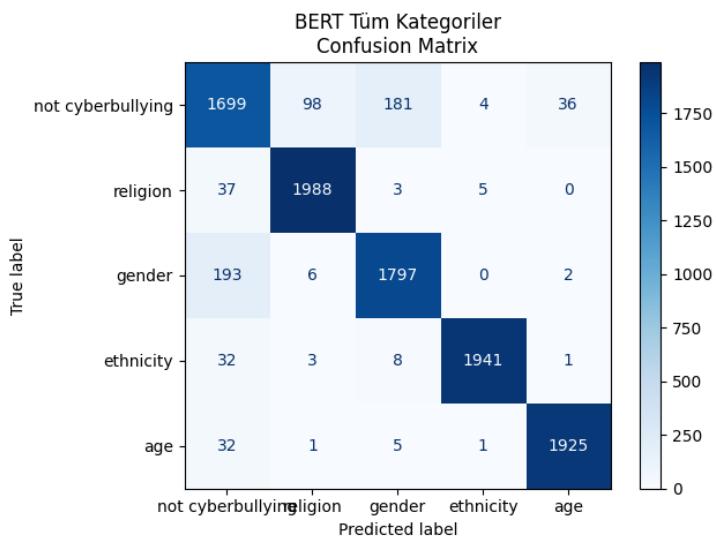
Şekil 8.76 LSTM Word2Vec İki Kategori

### 8.2.6 BERT

BERT kullanarak elde edilen sonuçlar Şekil 8.77, Şekil 8.79, Şekil 8.78, Şekil 8.80'lerde görülmektedir.

	precision	recall	f1-score	support
not cyberbullying	0.85	0.84	0.85	2018
religion	0.95	0.98	0.96	2033
gender	0.90	0.90	0.90	1998
ethnicity	0.99	0.98	0.99	1985
age	0.98	0.98	0.98	1964
accuracy			0.94	9998
macro avg	0.94	0.94	0.94	9998
weighted avg	0.94	0.94	0.94	9998

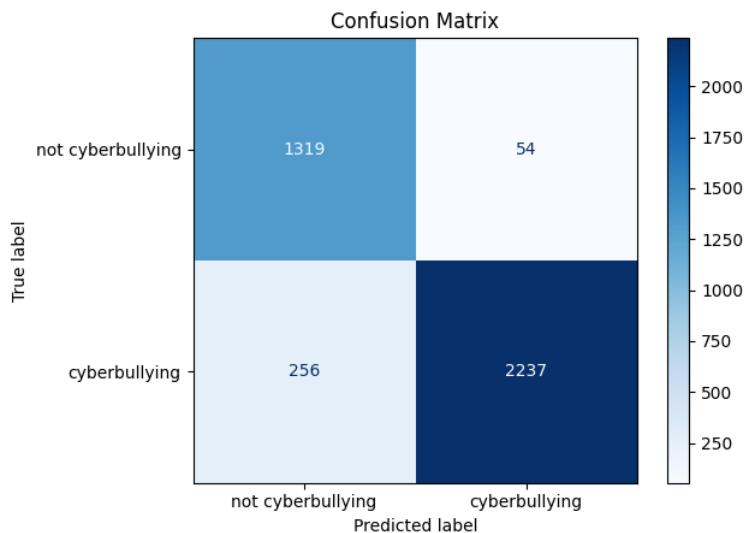
Şekil 8.77 BERT Tüm Kategoriler Model Performansı



**Şekil 8.78** BERT Tüm Kategoriler

	precision	recall	f1-score	support
0	0.84	0.96	0.89	1373
1	0.98	0.90	0.94	2493
accuracy			0.92	3866
macro avg	0.91	0.93	0.92	3866
weighted avg	0.93	0.92	0.92	3866

**Şekil 8.79** BERT İki Kategori Model Performansı



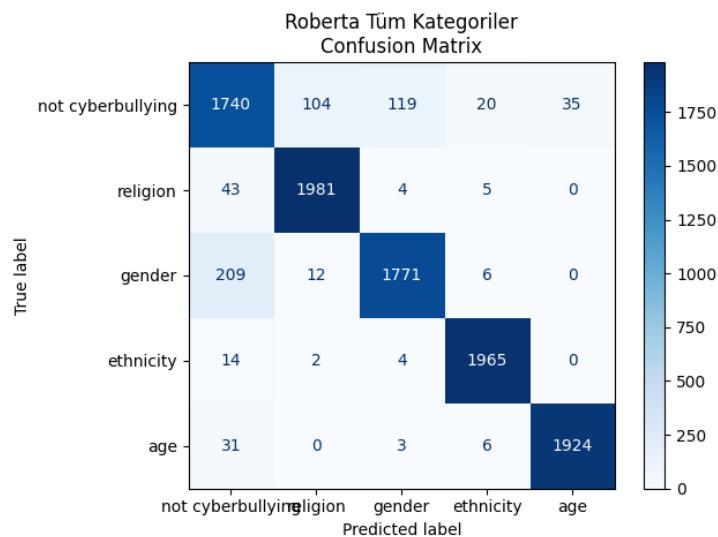
**Şekil 8.80** BERT İki Kategori

### 8.2.7 RoBERTa

RoBERTa kullanarak elde edilen sonuçlar Şekil 8.81, Şekil 8.83, Şekil 8.82, Şekil 8.84'lerde görülmektedir.

	precision	recall	f1-score	support
not cyberbullying	0.85	0.86	0.86	2018
religion	0.94	0.97	0.96	2033
gender	0.93	0.89	0.91	1998
ethnicity	0.98	0.99	0.99	1985
age	0.98	0.98	0.98	1964
accuracy			0.94	9998
macro avg	0.94	0.94	0.94	9998
weighted avg	0.94	0.94	0.94	9998

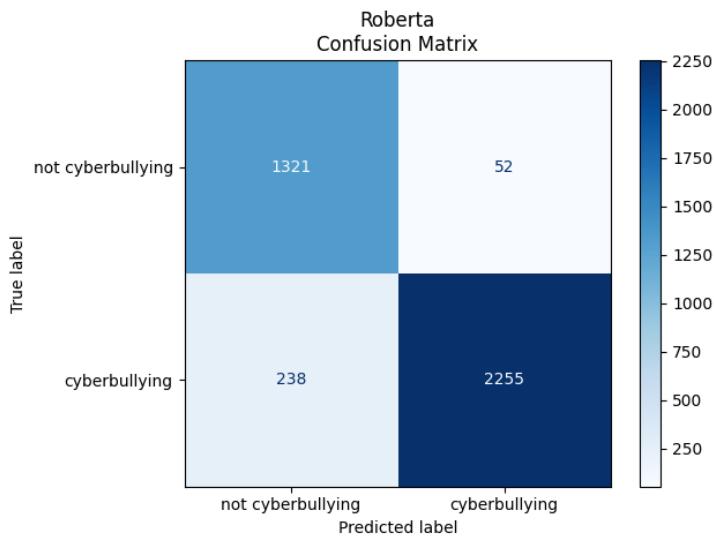
Şekil 8.81 RoBERTa Tüm Kategoriler Model Performansı



Şekil 8.82 RoBERTa Tüm Kategoriler

	precision	recall	f1-score	support
0	0.85	0.96	0.90	1373
1	0.98	0.90	0.94	2493
accuracy			0.92	3866
macro avg	0.91	0.93	0.92	3866
weighted avg	0.93	0.92	0.93	3866

Şekil 8.83 RoBERTa İki Kategori Model Performansı



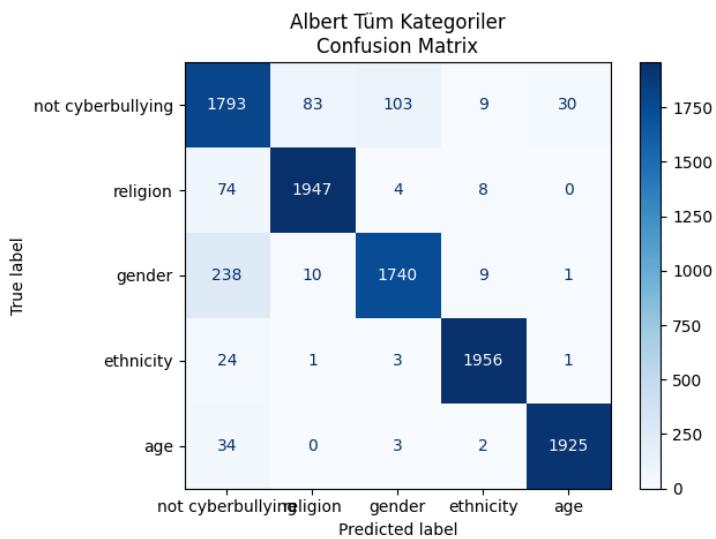
**Şekil 8.84** RoBERTa İki Kategori

### 8.2.8 ALBERT

ALBERT kullanarak elde edilen sonuçlar Şekil 8.85, Şekil 8.87, Şekil 8.86, Şekil 8.88'lerde görülmektedir.

	precision	recall	f1-score	support
not cyberbullying	0.83	0.89	0.86	2018
religion	0.95	0.96	0.96	2033
gender	0.94	0.87	0.90	1998
ethnicity	0.99	0.99	0.99	1985
age	0.98	0.98	0.98	1964
accuracy			0.94	9998
macro avg	0.94	0.94	0.94	9998
weighted avg	0.94	0.94	0.94	9998

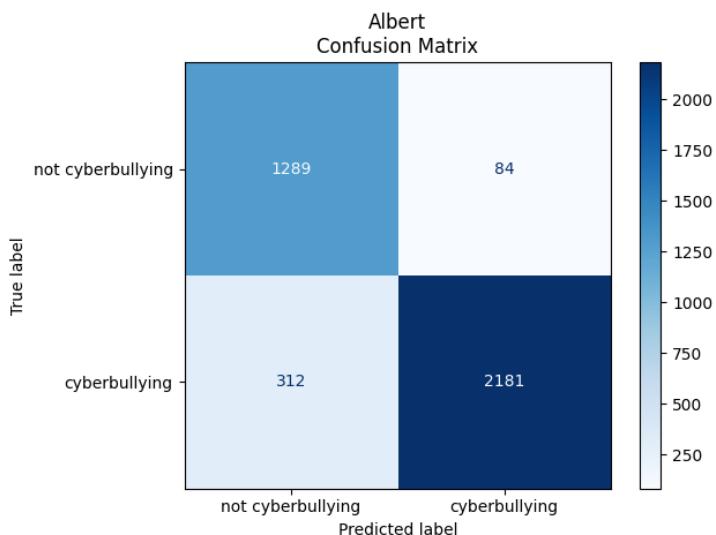
**Şekil 8.85** ALBERT Tüm Kategoriler Model Performansı



**Şekil 8.86** ALBERT Tüm Kategoriler

	precision	recall	f1-score	support
0	0.81	0.94	0.87	1373
1	0.96	0.87	0.92	2493
accuracy			0.90	3866
macro avg	0.88	0.91	0.89	3866
weighted avg	0.91	0.90	0.90	3866

**Şekil 8.87** ALBERT İki Kategori Model Performansı



**Şekil 8.88** ALBERT İki Kategori

# 9 Sonuç

---

Bu bölümde elde edilen en son sonuçlar karşılaştırılacaktır ve daha önce aynı veri setini kullanan araştırmalar ile elde edilen sonuçlar inceleneciktir.

## 9.1 Makine Öğrenme Modellerinin Karşılaştırması

Bu kısımda makine öğrenmeleri yöntemlerinden elde edilen sonuçlar TF-IDF ve CV vektörleştirme yöntemleri kullanmalarına göre doğruluk oranları verilerek Tablo 9.1'de karşılaştırılmıştır.

**Tablo 9.1** Makine Öğrenme Modellerinin Doğruluk Oranları Karşılaştırması

Vektörleştirme Yöntemi	Kategori Sayısı	SVM	LR	KNN	MNB
CV	Beş	0.94	0.94	0.82	0.88
TF-IDF	Beş	0.93	0.93	0.86	0.85
CV	İki	0.93	0.93	0.82	0.84
TF-IDF	İki	0.91	0.91	0.84	0.87

Genel olarak SVM ve LR'nin en başarılı makine öğrenme yöntemleri olduğu tespit edilmiştir. Elde edilen sonuçlar birbirlerine çok yakın olmuştur. Her vektörleştirme yönteminde ve kategori sayısı değiştiğinde verdikleri sonuçların aynı olduğu gözlemlenmiştir.

Beş kategori kullanıldığında genel olarak Count Vectorizer (CV) yönteminin TF-IDF yönteminden daha başarılı sonuçlar verdiği gözlemlenmiştir. CV yöntemi, KNN kullanılırken TF-IDF yönteminden geri kalırken diğer üç yöntemde TF-IDF yönteminin önüne geçmiştir.

İki kategori kullanıldığında ise başarılı olunan model miktarlarının eşit olduğu gözlemlenmiştir. SVM ve LR kullanıldığında CV daha başarılı olmuş, KNN ve MNB kullanıldığında ise TF-IDF daha başarılı olmuştur.

## 9.2 Derin Öğrenme Modellerinin Karşılaştırması

Bu kısımda proje kapsamında eğitilen derin öğrenme modellerinin verdikleri performanslar karşılaştırılacaktır. Bu modellerden alınan sonuçlar Tablo 9.2'de verilmiştir.

**Tablo 9.2** Derin Öğrenme Modellerinin Doğruluk Oranları Karşılaştırması

Modeller	Vektörleştirme Metodu	Kategori Sayısı	Doğruluk
LSTM	BERT	5	0.91
LSTM	FastText	5	0.93
LSTM	Word2Vec	5	0.93
LSTM	BERT	2	0.93
LSTM	FastText	2	0.91
LSTM	Word2Vec	2	0.91
BERT	BERT	5	0.94
BERT	BERT	2	0.92
RoBERTa	RoBERTa	5	0.94
RoBERTa	RoBERTa	2	0.92
ALBERT	ALBERT	5	0.94
ALBERT	ALBERT	2	0.90

Sonuçlara bakıldığından iki kategorili sınıflandırmalarda daha düşük oranlar görülmüştür. Bunun sebebi olarak veri setindeki örneklerin sayısı her sınıfta aynı olması hedeflendiğinden veri setinin küçültülmesi düşünülmektedir. Modellerde beş kategorili sınıflandırma yapılrken 47k uzunlukta veri seti kullanılırken iki kategorili sınıflandırmada da 18k uzunlukta bir veri seti kullanılmıştır.

Tüm modellerin performansına bakıldığından beş kategorili sınıflandırmada en iyi sonucu 0.94 doğruluk oranı ile BERT modelleri vermiştir. İki kategoride ise en iyi sonucu 0.93 doğruluk oranı ile BERT vektörleştirme metodu ile LSTM vermiştir.

## 9.3 Önceki Araştırmalar İle Karşılaştırma

Burada aynı veri seti üzerinde yapılan önceki çalışmalar karşılaştırılacaktır. Tablo 9.3'de diğer araştırmalarla bu projede elde edilen sonuçlar verilmiştir.

**Tablo 9.3** Karşılaştırma Tablosu

Çalışmalar	SVM	LR	KNN	MNB	BERT	RoBERTa
Projemiz	0.94	0.94	0.86	0.88	0.94	0.94
Ishtyaq ve arkadaşları [18]		0.83				
Yasmine ve arkadaşları [19]	0.91	0.90				
Arwa ve arkadaşları [20]	0.82		0.74	0.85	0.93	0.95

SVM modeline bakıldığında bu proje kapsamında elde edilen sonuçların daha önceki çalışmalardan yüzde üç gibi büyük bir oranla önüne geçtiği görülmüştür.

LR modeline bakıldığında ise daha önceki çalışmalara göre en az yüzde dörtlük bir fark ile bu yöntemde öne geçilmiştir.

KNN modelinde, bu projenin daha önceki çalışmalara göre yüzde on iki önüne geçtiği görülmüştür.

MNB kullanıldığında ise yüzde üç fark ile bu projenin diğer araştırmaların önüne geçtiği gözlemlenmiştir.

BERT modelinde diğer projenin önüne yüzde bir fark ile geçirilirken RoBERTa kullanıldığında bu proje yüzde bir geride kalmıştır.

Genel olarak elde edilen sonuçlar incelediğinde ve bu veri setini kullanan önceki veri setlerine bakıldığında bu proje kapsamında elde edilen sonuçlar diğer araştırmalara kıyasla daha başarılı olduğu sonucuna varılmıştır. Bu başarı farkının sebebi olarak modellere verilen hiper parametrelerin bir çok parametre denemesiyle seçilmesi olduğu düşünülmektedir. Ayrıca ön işleme adımda uygulanan tekniklerin değişikliğinin de sonuçta önemli bir etkisinin olduğu düşünülmektedir.

## Referanslar

---

- [1] Ç. Koçak and T. YİĞİT, “Gpt-3 sınıflandırma modeli ile türkçe twitlerin siber zorbalık durumlarının belirlenmesi,” *Gazi Mühendislik Bilimleri Dergisi*, vol. 9, no. 4-ICAIAME 2023, pp. 278–285, 2023.
- [2] G. NERGİZ and E. AVAROĞLU, “Türkçe sosyal medya yorumlarındaki siber zorbalığın derin öğrenme ile tespiti,” *Avrupa Bilim ve Teknoloji Dergisi*, no. 31, pp. 77–84, 2021.
- [3] E. YAZĞILI and M. BAYKARA, “Türkçe metinlerde makine öğrenmesi yöntemleri ile siber zorbalık tespiti,” *Gümüşhane Üniversitesi Fen Bilimleri Dergisi*, vol. 12, no. 2, pp. 443–453, 2022.
- [4] O. SEVLİ and S. SEZGIN, “Sosyal medya paylaşımlarında siber zorbalığın tespiti ve kategorizasyonuna yönelik makine öğrenmesine dayalı bir sınıflandırma,”
- [5] Larxel. “Cyberbullying classification.” (2020), [Online]. Available: <https://www.kaggle.com/datasets/andrewmd/cyberbullying-classification/data> (visited on 04/22/2024).
- [6] R. Shah. “Introduction to k-nearest neighbors (knn) algorithm.” (2021), [Online]. Available: <https://ai.plainenglish.io/introduction-to-k-nearest-neighbors-knn-algorithm-e8617a448fa8> (visited on 05/24/2024).
- [7] Natassha. “Logistic regression explained in 7 minutes.” (2022), [Online]. Available: <https://www.natasshaselvaraj.com/logistic-regression-explained-in-7-minutes/> (visited on 05/24/2024).
- [8] E. YAZĞILI and M. BAYKARA, “Siber zorbalık tespit yöntemleri potansiyel uygulama alanları ve zorluklar,” *Dicle Üniversitesi Mühendislik Fakültesi Mühendislik Dergisi*, vol. 12, no. 1, pp. 23–35, 2021.
- [9] Anonymous. “What is the naive bayes algorithm?” (2022), [Online]. Available: <https://databasecamp.de/en/ml/naive-bayes-algorithm> (visited on 05/24/2024).
- [10] Hichigo. “Scikit-learn ile destek vektör makineleri (svm).” (2020), [Online]. Available: <https://www.turkhackteam.org/konular/scikit-learn-ile-destek-vektor-makineleri-svm.1909633/> (visited on 05/24/2024).
- [11] O. Akköse. “Uzun-kısa vadeli bellek(lstm).” (2020), [Online]. Available: <https://medium.com/deep-learning-turkiye/uzun-k%C4%B1sa-vadeli-bellek-lstm-b018c07174a3> (visited on 05/24/2024).

- [12] K. Mani. “Gru’s and lstm’s.” (2019), [Online]. Available: <https://towardsdatascience.com/grus-and-lstm-s-741709a9b9b1> (visited on 05/24/2024).
- [13] J. Schulze. “What is the bert model and how does it work?” (2024), [Online]. Available: <https://www.coursera.org/articles/bert-model> (visited on 05/24/2024).
- [14] J. D. M.-W. C. Kenton and L. K. Toutanova, “Bert: Pre-training of deep bidirectional transformers for language understanding,” in *Proceedings of naacl-HLT*, vol. 1, 2019, p. 2.
- [15] S. Kotamraju. “Everything you need to know about albert, roberta, and distilbert.” (2022), [Online]. Available: <https://towardsdatascience.com/everything-you-need-to-know-about-albert-roberta-and-distilbert-11a74334b2da> (visited on 05/24/2024).
- [16] M. Zampieri, S. Malmasi, P. Nakov, S. Rosenthal, N. Farra, and R. Kumar, “Predicting the Type and Target of Offensive Posts in Social Media,” in *Proceedings of NAACL*, 2019.
- [17] Crowdflower. “Hate speech identification.” (2016), [Online]. Available: <https://data.world/crowdflower/hate-speech-identification> (visited on 05/24/2024).
- [18] M. I. Mahmud, M. Mamun, and A. Abdelgawad, “A deep analysis of textual features based cyberbullying detection using machine learning,” in *2022 IEEE Global Conference on Artificial Intelligence and Internet of Things (GCAIoT)*, IEEE, 2022, pp. 166–170.
- [19] Y. M. Ibrahim, R. Essameldin, and S. M. Saad, “Social media forensics: An adaptive cyberbullying-related hate speech detection approach based on neural networks with uncertainty,” *IEEE Access*, 2024.
- [20] F. Alrowais *et al.*, “Robertanet: Enhanced roberta transformer based model for cyberbullying detection with glove features,” *IEEE Access*, 2024.

# Özgeçmiş

---

## BİRİNCİ ÜYE

**İsim-Soyisim:** Yavuz ÇETİN  
**Doğum Tarihi ve Yeri:** 16.10.2002, İstanbul  
**E-mail:** yavuz.cetin1@std.yildiz.edu.tr  
**Telefon:** 0538 812 19 36  
**Staj Tecrübeleri:**

## İKİNCİ ÜYE

**İsim-Soyisim:** Osman Berkay SUKAS  
**Doğum Tarihi ve Yeri:** 19.07.2001, İstanbul  
**E-mail:** berkay.sukas@std.yildiz.edu.tr  
**Telefon:** 0553 657 135 53  
**Staj Tecrübeleri:**

## Proje Sistem Bilgileri

**Sistem ve Yazılım:** Windows İşletim Sistemi, Python  
**Gerekli RAM:** 32GB  
**Gerekli Disk:** 1TB